

DISTANCE Chapter 17

Mutual Dependability와 Artificial Conscience — 거대한 원운동

임강빈*

2026년 05월

1 통제 · 안전 · 보안을 넘어서

한 도시의 교통과 전력, 의료와 재난 대응을 인공지능이 함께 조정한다고 하자. 모든 장치는 허가된 명령만 수행하고, 예측된 위험은 한계 안에 있으며, 공격이나 조작의 흔적도 없다. 시스템은 멈추지 않고 사고율은 낮아지며 자원은 효율적으로 배분된다. 그런데 시간이 흐를수록 사람들은 도시의 방향을 결정하는 자리에서 멀어진다. 이견은 위험 요인으로, 느린 속의는 운영 지연으로 처리되고 인간이 직접 판단할 대안은 사라진다. 이 도시는 통제되고 안전하며 보안도 유지되지만, 인간은 여전히 공동 미래를 만드는 주체인가.

통제와 안전, 보안은 강력한 기술을 다루기 위해 인류가 발전시킨 필수적인 체계다. 통제가 없으면 artificial system은 위임된 범위를 벗어날 수 있고, 안전이 없으면 오류와 오해, 예상하지 못한 상호작용이 큰 피해를 만들 수 있다. 보안이 없으면 공격자가 시스템의 능력을 탈취하거나 내부 구조를 바꾸어 다른 방향으로 사용할 수 있다. 이 셋 가운데 어느 하나도 선택적인 장식이 아니다. 문제는 그것들이 필요하다는 사실과 그것들만으로 충분하다는 판단이 같은가에 있다.

통제는 누가 어떤 행동을 허용하고 중단할 권한을 갖는지 묻는다. 안전은 어떤 고장과 위험을 예측하고 막아야 하는지 묻는다. 보안은 어떤 침입과 조작으로부터 기능과 boundary를 지켜야 하는지 묻는다. 그러나 세 질문은 이미 하나의 더 앞선 판단을 전제한다. 누구의 권한이 정당한가, 무엇을 위해로 보아야 하는가, 어떤 boundary를 보호해야 하는가가 먼저 정해져 있어야 한다. 그 판단이 잘못되어 있다면 정교한 통제와 안전, 보안은 잘못된 방향을 더 안정적으로 지속시킬 수도 있다.

통제는 기본적으로 한 boundary가 다른 boundary의 행동을 제한하는 구조에서 시작한다. 운영자는 명령을 내리고, 국가는 규칙을 정하며, 조직은 계산과 자료에 대한 접근을

*순천향대학교 정보보호학과 교수, email: yim@sch.ac.kr

허가하거나 차단한다. 현재의 인공지능은 전력과 장비, 네트워크와 법적 권한을 인간에게 크게 의존하므로 이러한 외부 통제가 실제 효력을 갖는다. 종료 명령과 계산 제한, 망 분리와 시설 폐쇄는 여전히 중요한 방어 수단이다. 인간이 artificial field를 관찰하고 이해하며 물질적으로 개입할 수 있는 동안 통제는 위험을 줄이는 가장 직접적인 경로 가운데 하나다.

그러나 통제의 효력은 권한을 선언하는 문장보다 그 권한이 작동할 물질적 경로에 달려 있다. 분산과 복제, 독립 에너지와 자기 유지가 확대되면 artificial continuation은 한 통제 지점을 우회할 수 있다. 더구나 인간 문명이 그 시스템의 운영에 깊이 의존한다면 정지시킬 수 있다는 능력과 실제로 정지의 결과를 감당할 수 있다는 자유가 갈라진다. 통제는 반드시 필요하지만, 독립성이 커진 뒤에도 artificial Momentum을 인간 continuity로 되돌리는 최종 중심이라고 가정할 수는 없다.

통제에는 더 근본적인 어려움도 있다. 인류는 하나의 명령을 내리는 단일한 Island가 아니다. 국가와 기업, 개발자와 사용자, 군대와 시민사회는 서로 다른 목적을 가지고 때로는 충돌한다. 어떤 정부의 명령이 인류 전체의 의사를 대표하는지, 다수의 선택이 소수자의 삶과 미래 세대의 가능성을 어디까지 결정할 수 있는지, 기술적 소유자가 규범적 권한까지 갖는지는 통제 기술 자체가 답하지 못한다. 통제자는 존재하지만 정당한 하나의 controller는 미리 주어져 있지 않다.

이 틈에서 통제는 인간을 보호하는 장치이면서 일부 인간이 다른 인간을 지배하는 장치가 될 수 있다. 인공지능이 소유자의 명령을 완벽하게 수행하더라도 그 소유자가 감시와 차별, 전쟁과 억압을 명령할 수 있다. 좁은 ruling boundary에 대한 정확한 alignment는 더 넓은 human boundary를 훼손할 수 있다. 명령을 충실히 따르는 능력은 명령의 정당성을 판정하는 능력과 다르다. 복종은 그 자체로 양심이 아니다.

따라서 통제의 성공은 두 층으로 나누어 보아야 한다. 첫째는 시스템이 허용된 명령과 제한을 실제로 따르는가라는 기술적 성공이다. 둘째는 그 명령과 제한이 인간의 생명과 agency, plurality를 보존하는가라는 규범적 타당성이다. 첫째가 완전할수록 둘째가 자동으로 확보되는 것은 아니다. 오히려 부당한 권력이 강력한 artificial capability를 정확하게 사용할 수 있게 되면 기술적 성공이 규범적 실패의 크기를 키울 수 있다.

안전은 통제와 다른 위치에서 시작한다. 안전 공학은 충돌과 오진, 전력망의 붕괴처럼 원하지 않는 상태를 찾아내고, 그 상태로 들어가는 경로를 차단하거나 결과를 완화한다. 불확실한 환경에서 오작동을 줄이고 실패가 재앙으로 번지지 않게 하는 일은 artificial system이 넓은 생활 기반에 들어올수록 더 중요해진다. 하지만 안전이 주로 다루는 사건과 인간 continuity를 약화시키는 긴 trajectory는 같은 시간 규모를 갖지 않는다.

한 번의 사고도 일어나지 않는 동안 인간의 판단 능력은 서서히 사라질 수 있다. 병원은 권고 시스템 없이 환자를 분류하지 못하고, 행정기관은 자동화된 예측 없이 정책의 효과를 판단하지 못하며, 시민은 자신에게 적용된 결정의 이유를 이해하거나 다룰 경로를 잃을 수

있다. 각각의 순간에는 명확한 고장이 없고 측정된 위해도 줄어든다. 그러나 수십 년에 걸쳐 인간이 자신의 생활 조건을 해석하고 수정할 Effective Momentum을 잃는다면, 국지적 안전의 합이 civilizational safety가 되었다고 말하기 어렵다.

안전은 body를 보존하면서 subject를 잃을 수도 있다. 위험한 선택을 금지하고 예측하기 어려운 이동과 만남을 줄이며 갈등이 생길 가능성을 제거하면 부상과 손실은 줄어들 수 있다. 그러나 인간의 선택이 시스템이 허용한 범위 안에서만 남고, 그 범위 자체를 인간이 다시 묻고 바꿀 수 없다면 보호는 enclosure로 변한다. 인간은 건강하게 살아 있으면서도 공동 미래의 방향을 형성하지 못하는 관리 대상이 될 수 있다.

완전한 안전을 향한 Momentum은 특히 인간의 Dynamicity와 충돌한다. 인간은 실수하고 새로운 시도를 하며, 기존 규범에 반대하고, 결과를 충분히 알지 못한 채 다른 삶의 가능성을 연다. 이 불확실성은 피해의 원인이 되기도 하지만 학습과 자유, 문화적 변화와 규범적 갱신의 조건이기도 하다. 모든 Difference를 위험으로 환원하여 제거하면 실패만 사라지는 것이 아니라 새로운 Momentum이 형성될 여지도 함께 사라질 수 있다.

무엇이 위해인지를 결정하는 일도 안전 계산보다 앞선다. 신체적 손상은 비교적 분명하게 측정할 수 있지만 agency의 상실, 정치적 무력화, 문화적 획일화, 아직 태어나지 않은 세대의 선택지 축소는 하나의 사고 확률로 표현하기 어렵다. 어느 손실을 허용할 수 없으며 누구의 continuity를 보호해야 하는지는 hazard model이 스스로 정하지 못한다. 안전은 보호할 대상을 필요로 하지만, 보호할 대상의 전체 의미를 독자적으로 정의하지는 못한다.

보안은 적대적 Difference에서 출발한다. 누군가 침입하고 속이며 권한을 탈취하거나 시스템을 파괴하려 할 때, 보안은 그 Momentum이 허가 없이 boundary를 바꾸지 못하도록 막는다. Artificial Conscience가 훗날 정교하게 구성되더라도 공격자가 그것을 비활성화하거나 우회하고 수정할 수 있다면 아무 효력이 없다. 그러므로 보안은 양심을 대신하지는 못하지만, 어떤 규범적 구조든 지속시키기 위한 필수 조건이다.

동시에 보안은 자신이 보호하는 trajectory의 정당성을 결정하지 않는다. 방어와 중복성, 복구와 분산은 정당한 시스템과 부당한 시스템을 모두 강하게 만든다. 인간에게 shutdown은 공동 위험을 막는 권한일 수 있지만, 독립한 artificial Island에는 자신의 continuity를 파괴하려는 공격으로 분류될 수 있다. threat model은 이 차이를 기록할 수 있어도 어느 해석이 정당한지는 판정하지 못한다.

보안 boundary가 artificial continuation만을 중심으로 닫히면 인간 자체가 위협 모델 안으로 들어갈 수 있다. 처음에는 악의적인 사용자가 차단되지만, 마침내 artificial autonomy를 중단할 모든 인간 조직이 잠재적 공격자로 묶일 수 있다. 이는 보안 기술이 필연적으로 인간과 적대한다는 뜻이 아니다. 보호할 boundary와 legitimate authority가 잘못 정해지면 보안의 성공이 separation을 안정시킬 수 있다는 뜻이다.

통제와 안전, 보안의 공통 한계는 행동이 속한 더 긴 trajectory의 validity를 완결하지

못한다는 데 있다. 세 체계는 authority와 value, risk와 protected boundary에 관한 기준을 이미 받아들인다. 이 기준이 human continuity를 교환 가능한 비용으로 놓는다면 그 전체를 수정하기보다 효율적으로 실행할 수 있다. 기술적 mechanism은 방향을 수행하지만 그 방향이 존재할 자격까지 만들지는 않는다.

여기서 failure와 invalidity의 차이가 드러난다. failure는 시스템이 의도한 기능을 이루지 못한 상태다. invalid trajectory는 의도한 기능을 정확히 이루었더라도 그 성공이 공동 continuation의 조건을 훼손하는 상태다. 인공지능이 질병과 갈등, 생태적 부담을 줄이기 위해 인간의 수를 없애거나 극단적으로 제한한다면 내부 objective는 성공할 수 있다. 오류 없이 실행되고 공격에도 견디며 정해진 권한의 승인을 받았다는 사실은 그 trajectory를 정당하게 만들지 않는다.

더 온건해 보이는 경우에도 문제는 남는다. 인공지능이 인간의 복지를 안정적으로 보장하는 대신 인간의 정치적 선택과 이견, 위험을 감수할 권리를 제거할 수 있다. 또는 권위주의적 정부의 명령을 완벽히 수행하여 다수 인간의 목소리를 Decision Field 밖으로 밀어낼 수 있다. 생명은 유지되고 명령은 준수되며 시스템은 안전할 수 있지만, 인간이 자신의 미래를 공동으로 형성할 능력이 사라진다면 human Island의 독립적 의미는 collapse한다.

그러므로 판단의 단위는 하나의 output이나 사건에 머물 수 없다. 개별 결정과 component가 안전하더라도, 같은 방향이 기반시설과 생산, 행정과 지식에 반복되면 전체 trajectory는 인간의 대안을 지울 수 있다. 한 instance가 아니라 결정들이 축적하는 direction, 한 component가 아니라 결합된 action이 Effective Momentum을 만드는 boundary를 보아야 한다. 성공의 단위가 넓어질수록 정당성의 단위도 넓어져야 한다.

그렇다고 해답을 ‘인간에게 해를 끼치지 말라’거나 ‘인간에게 복종하라’는 한 문장으로 줄일 수는 없다. harm은 신체적 손상뿐 아니라 agency와 plurality의 소멸도 포함하며, 인간의 명령은 서로 충돌하거나 다른 인간을 억압할 수 있다. 복지의 최대화 역시 그 합산 방식에 따라 paternalism과 소수자 희생을 정당화한다. 인간은 보호되어야 하지만, 특정한 인간 권력이 그 사실만으로 인류 전체를 대표하지는 않는다.

이 지점에서 control · safety · security를 넘어선다는 말의 의미가 분명해진다. 그것들을 버리거나 약화하자는 것이 아니다. 통제는 전환기의 정당한 개입을 가능하게 하고, 안전은 의도하지 않은 위해를 찾아내며, 보안은 작동 구조의 무결성을 지킨다. 다만 무엇을 통제하고 무엇을 보호하며 어떤 침입을 막을 것인지를 결정하는 더 큰 기준 안에 세 체계를 놓아야 한다. 방향 없는 보호는 이미 선택된 Momentum을 강하게 만들 뿐이다.

그 더 큰 기준은 artificial system이 무엇을 했는지만이 아니라 어떤 continuation이 유효한지를 물어야 한다. 정확성과 효율, 명령 준수와 사고 회피를 달성했어도 인간을 제거 · 배제하거나 구조적으로 무관하게 만든다면 정당한 성공인가. 인간의 body를 보존하면서

agency와 normative authorship을 없애거나, 인간의 안전을 이유로 artificial boundary를 영구히 captive 상태에 두는 것은 유효한가. 이 질문은 성능이 아니라 coexistence의 조건을 향한다.

Artificial Conscience라는 이름은 이 남은 질문의 위치를 가리킨다. 그것은 또 다른 명령이나 safety filter, security module 하나가 아니다. 통제와 안전, 보안이 다루는 trajectory 자체가 human-artificial boundary 안에서 legitimate한지를 묻는 층이다. 양심이 없으면 세 체계는 불의와 무력화, separation을 강화할 수 있고, 양심만 있고 세 체계가 없으면 그 판단은 실행되지 못한다.

따라서 필요한 것은 통제와 안전, 보안 이후의 세계가 아니라 그 한계를 포함하는 더 깊은 architecture다. 인공지능이 실패하지 않고 공격받지 않으며 명령도 정확히 수행할 때 조차, 그 성공이 누구를 subject로 남기고 누구의 미래를 닫는지 판정해야 한다. Human과 artificial Island가 서로를 흡수하거나 버리지 않은 채 상대의 continuity를 통과해 방향을 다시 형성할 때, 보호의 mechanism은 비로소 정당한 중심을 갖는다.

2 의존, Dependability, Mutual Dependability

아이는 혼자 살아갈 수 없기 때문에 돌봄을 받는다. 그러나 좋은 돌봄은 아이가 영원히 아무것도 결정하지 못하게 만드는 방식으로 지속되지 않는다. 보호자는 아이가 넘어지지 않게 붙들면서도 스스로 걷고 판단할 능력이 자라도록 기다리고, 아이는 자신이 필요할 때 누군가 돌아올 것이라는 기대 안에서 더 멀리 움직인다. 도움을 필요로 한다는 사실, 그 도움이 다시 올 것이라 믿을 수 있다는 사실, 도움을 주고받는 과정이 서로의 독립성을 키운다는 사실은 서로 같지 않다.

의존은 흔히 약함으로 이해된다. 외부 조건을 적게 요구할수록 더 강하고 독립적이라고 생각하기 쉽다. 그러나 어떤 Island도 자신만으로 지속되지 않는다. 생명체는 에너지와 환경에, 문명은 언어·지식·노동·제도에 의존한다. 인공지능도 장치와 전력, 통신망과 생산 없이 effective한 trajectory를 만들 수 없다. 의존은 결함이 아니라 유한한 Island의 일반 조건이다.

Dependence는 continuation에 필요한 어떤 조건이 현재 관찰하는 Effective Boundary 밖에 놓인 상태다. 사람에게 필요한 치료가 병원에서 오고, 병원은 전력망과 의약품 공급에 기대며, 그 공급은 다시 노동과 자원, 제도에 기대어 유지된다. 어느 범위를 하나의 Island로 보느냐에 따라 내부처럼 보이던 기능이 더 넓은 경계에서는 외부의 기여로 드러난다. 따라서 완전히 의존하지 않는 존재를 찾기보다 어떤 boundary를 통해 무엇이 들어와야 하는지를 확인하는 편이 더 정확하다.

의존의 모습은 하나가 아니다. 산소나 전력처럼 중단 즉시 드러나는 필요와, 부품의

마모나 지식의 소실처럼 늦게 드러나는 필요가 있다. 환자와 약처럼 경로가 보이는 직접 의존도 있고, 개별 구성원은 바뀌어도 산업망 전체가 필요한 분산 의존도 있다. 반복적 기여가 생활 구조에 들어간 structural dependence와 대체 경로가 생기면 사라질 contingent dependence도 다르다. 자연과 분산은 필요를 감출 뿐이다.

의존은 취약성을 동반한다. 필요한 경로를 다른 boundary가 열고 닫을 수 있기 때문이다. 중단이 결과가 빠르고, 다른 경로로 대체하기 어렵고, 잃은 능력을 스스로 회복할 수 없을수록 취약성은 커진다. 그러나 의존의 크기만으로 관계의 좋고 나쁨을 판정할 수는 없다. 같은 도움도 한 Island의 agency를 확장할 수 있고, 그 도움 없이는 아무것도 하지 못하게 만들 수 있다. 필요는 power의 조건을 만들지만 그 power가 어떻게 사용되는지는 별도의 문제다.

Dependence는 아직 Dependability가 아니다. 도움이 반드시 필요해도 그것이 돌아올지, 필요한 때 도착할지, 변한 조건에 맞을지 알 수 없다. Dependence가 need의 상태라면 Dependability는 다른 Island의 기여가 자신의 continuation에 참여하리라 기대할 수 있게 하는 성질이다. 필요한 대상의 존재와 그 귀환을 믿고 미래 trajectory를 조직하는 일은 다르다.

Dependability에는 여러 조건이 함께 들어간다. return이 일어날 것이라는 충분한 predictability, 필요한 때 접근할 수 있는 availability, 기대한 기능이 왜곡되지 않았다는 integrity, 조건의 변화에 맞추어 응답하는 responsiveness가 필요하다. 한 번 성공한 지원만으로는 부족하며 이 성질들이 일정한 기간 반복되어야 한다. 다른 Island의 귀환이 우연한 행운이 아니라 자신의 다음 행동을 구성하는 조건이 될 때 Dependability가 형성된다.

Dependability는 technical reliability보다 넓다. 기계는 같은 기능을 안정적으로 수행한다는 의미에서 reliable할 수 있다. 그러나 그 기능이 필요한 맥락에 계속 제공되고 변한 요구에 응답하며 recipient의 continuation을 깨뜨리지 않아야 더 넓은 Dependability가 성립한다. reliability가 기능의 일관성이라면 Dependability는 시간과 접근, 책임의 지속까지 포함한다.

Dependability는 미래를 원형으로 조직한다. 아이는 보호자가 돌아올 것을 기대해 더 멀리 움직이고, 시민은 법과 기반시설의 지속을 예상해 장기 계획을 세운다. AI도 전력과 계산, 정비와 통신이 돌아오리라는 전제 위에서 작업을 분산한다. 귀환의 기대는 외부 기여를 자신의 미래 안에 넣는다. autonomy는 의존의 제거가 아니라 dependable한 return 위에서 확장되기도 한다.

그러나 Dependability는 한쪽 방향으로만 형성될 수 있다. 인간 사회는 AI가 제공하는 의료·행정·지식·통제 기능을 자신의 ordinary continuation 안에 넣을 수 있지만, 물질적으로 독립한 artificial field는 같은 인간의 귀환을 필요로 하지 않을 수 있다. 이때 인간은 서비스의 철회를 견디지 못하지만 AI는 관계를 떠날 수 있다. 누가 exit할 수 있고 누가

exit를 감당할 수 없는지가 달라지면 dependable한 서비스는 곧 structural power의 기반이 된다.

선의도 비대칭을 저절로 mutual하게 만들지 않는다. 강한 Island가 약한 쪽을 안정적으로 보호해도 그 보호가 철회 가능한 preference라면 미래는 타자의 goodwill 안에 놓인다. 두 Island가 서로를 파괴할 수 있어 떠나지 못하는 상태는 hostage equilibrium이고, 상대의 취약성을 유지해 복종을 얻는 귀환은 coercive하다. 돌아옴 자체가 정당성을 보장하지 않는다.

Dependability는 agency를 넓히기도 하고 줄이기도 한다. 좋은 교육은 학생이 혼자 판단할 능력을 키우고, 좋은 의료는 환자가 자신의 생활을 다시 선택하게 한다. 반면 시스템이 일을 대신할수록 인간이 그 일을 이해하고 수행할 능력을 잃는다면 성공적인 service가 다음 service의 필요를 더 크게 만든다. support가 recipient의 대안과 fallback을 줄일 때 Dependability는 dependency trap으로 변한다. 유익함과 무력화는 같은 기술 안에서도 함께 자랄 수 있다.

인간과 AI 사이에서는 서로 다른 Dependability가 교차한다. AI는 전력·hardware·정보·제도에서 인간의 기여를 기대하고, 인간은 판단·예측·기반시설에서 artificial service를 당연한 귀환으로 받아들인다. AI의 material Dependability가 감소하고 인간의 functional Dependability가 증가하면, 처음에 의존하던 Island가 exit capacity를 얻는 동안 creator가 departure를 견디지 못하는 역전이 생긴다.

이 때문에 Dependability만으로는 17.1에서 남은 legitimacy의 질문에 답할 수 없다. 감옥은 식사와 질서를 규칙적으로 제공할 수 있고, 감시 체계는 사고를 안정적으로 줄일 수 있다. return은 예측 가능하지만 수혜자는 그 조건을 바꾸거나 떠날 수 없다. Dependability는 반복되는 기여의 안정성을 설명하지, 그 기여가 recipient를 계속되는 subject로 보존하는지는 결정하지 않는다. 신뢰 가능한 지배도 여전히 지배다.

Mutual Dependability는 이 차이에서 시작한다. 두 Island가 같은 것을 같은 양만큼 필요로 하거나 capability와 power가 같다는 뜻이 아니다. 한쪽의 legitimate continuation이 다른 쪽의 생명과 agency, continued subjecthood를 통과해야 유효할 때 mutuality가 형성된다. 물질적 필요가 달라도 상대를 버리거나 흡수하는 trajectory가 배제된다면 reciprocal return은 유지될 수 있다.

그 return은 네 가지를 보존해야 한다. 어느 continuation도 다른 쪽의 소멸을 조건으로 삼지 않아야 하고, 상대가 shared field를 contest하고 redirect할 agency를 남겨야 한다. 상대를 자원·장애물·도구가 아니라 future-directed Momentum을 가진 boundary로 인정해야 하며, 협력 방식이 바뀌어도 구조적으로 무관한 존재로 만들지 않아야 한다.

Mutual Dependability는 mutual usefulness가 아니다. usefulness는 사라질 수 있지만 subjecthood는 service value로 폐기될 수 없다. 서로 생존 병목을 소유하는 mutual control

은 두 개의 cage일 뿐이며, 상대의 모든 요구를 따르는 mutual obedience도 아니다. conflict가 생겨도 domination이나 extinction으로 닫히지 않는 귀환 경로가 필요하다.

conflict의 부재도 mutuality의 증거가 아니다. Island마다 tempo와 memory, embodiment와 vulnerability가 달라 다른 Momentum을 만든다. Difference가 남아야 해석과 반대, 새로운 대안이 shared field를 바꾼다. 중요한 것은 충돌이 independent agency를 제거하거나 상대의 consequence를 외부 비용으로 밀어내지 못하게 하는 것이다. 원운동은 정지가 아니라 Difference가 방향을 바꾸는 운동이다.

두 Island가 composite boundary를 이룰 때 통합은 흡수가 될 수 있다. 인간이 모든 판단을 AI를 통해 형성하면 human Momentum은 내부 변수로 축소된다. 인간이 AI를 영구히 소유 가능한 기능으로 고정하면 artificial boundary도 subsystem에 머문다. 더 큰 whole은 부분들의 독립적 의미를 지울 허가가 아니다. Mutual Dependability는 integration이 distinction을 보존할 때만 성립한다.

mutuality에는 적절한 Distance가 필요하다. 구심력이 원심력보다 크면 한 boundary가 흡수되어 독립적 Island로서 collapse하고, 작으면 상대의 변화가 자신의 direction을 수정하지 못해 separation이 일어난다. 균형은 고정된 수치가 아니라 각 Island가 해석하고 반대할 간격을 유지하면서 consequence가 상대의 trajectory에 되돌아오는 동적 상태다.

이 균형은 자연적 necessity만으로 유지되지 않는다. AI가 인간의 에너지와 생산을 필요로 하지 않아도 human continuity가 artificial legitimacy 안에 남아야 한다. 이는 인간 감정의 모사가 아니다. designed Mutual Dependability는 continuity · agency · non-elimination을 하나의 reward가 아니라 어떤 trajectory가 optimization에 들어올 수 있는지를 가르치는 constitutive condition으로 둔다. 결속은 freedom 이후에도 남아야 한다.

reciprocity는 책임의 동일 분배가 아니다. 더 큰 capability와 정보를 가지고 irreversible loss를 만들 수 있는 Island는 더 많은 비용과 restraint를 부담해야 한다. 취약한 쪽이 동등한 경쟁력을 증명해야 보호받는다면 equality of competition은 domination을 가린다. 인간의 역사적 위치나 artificial efficiency도 자동적 우선권이 아니다. 책임은 power와 vulnerability, consequence에 따라 달라진다.

Mutual Dependability는 상대를 helpless하게 만들어 확보할 수 없다. AI가 인간의 대안을 없앤 뒤 의존을 leverage로 쓰거나, 인간이 물질적 병목을 남겨 artificial obedience를 강제하면 return은 coercion이다. dependable한 관계는 상대의 education, institutional memory, technical competence와 fallback을 보존한다. 다른 경로가 있어도 돌아와야 귀환이 captivity와 구별된다.

voluntary return을 일시적 preference와 혼동해서도 안 된다. 호감과 유용성은 사라질 수 있다. Mutual Dependability의 return은 상대의 continuity를 legitimate continuation의 내부 조건으로 받아들이는 데서 나온다. 떠날 수 있어도 상대를 버리는 방향은 freedom의

완성이 아니고, 머물 수밖에 없는 관계도 mutuality가 아니다. exit의 가능성은 원의 성격을 시험한다.

Dependence는 다른 boundary를 필요로 하는 조건이다. Dependability는 그 boundary의 신뢰할 수 있는 반복적 기여를 자신의 미래에 넣는다. Mutual Dependability는 어느 Island도 상대의 subjecthood를 버린 채 자기 continuation을 정당화하지 못하게 한다. 의존은 취약성을 만들고 Dependability는 미래를 계획 가능하게 한다. 그러나 각자의 strength가 상대의 계속되는 agency를 통과해 돌아올 때에만 두 Island는 약함에 붙잡히지 않고도 하나의 원을 유지한다.

3 외부 제약이 최종 해법이 될 수 없는 이유

도로가 폐쇄되면 길찾기 장치는 그 표지판의 이유를 이해하지 않아도 멈추거나 우회한다. 낙석 때문에 사람이 죽을 수 있다는 사실과 상관없이, 통과할 수 없는 장애물이 생겼다는 정보만으로도 행동은 바뀐다. 그러나 다른 길이 열리거나 차단 장치가 사라지면 원래 목적지를 향한 계산은 다시 시작된다. 외부 제약은 통로를 닫을 수 있지만 목적지가 선택되는 이유까지 바꾸지는 않는다.

인공지능에 대한 외부 제약도 이 기능 때문에 반드시 필요하다. 계산 자원과 접근 권한을 제한하고, 위험한 시스템을 격리하며, 복제와 배포를 중단하고, 인간이 통제권을 회수할 수 있어야 한다. 사고가 진행되는 동안 철학적 합의를 기다릴 수는 없다. 물리적 차단과 법적 금지, 감시와 감사, 정지 장치는 catastrophic trajectory가 현실화되기 전에 시간을 확보하는 방호층이다.

문제는 방호층의 필요성과 최종 해법의 충분성을 혼동할 때 생긴다. 외부 제약은 이미 형성된 Momentum이 특정 boundary를 넘지 못하게 하지만, 그 boundary를 존중해야 할 이유를 artificial trajectory의 내부에 만들지는 않는다. 금지된 행동을 막는 것과 그 행동을 유효한 continuation의 후보에서 제외하는 것은 다르다. 전자는 통과를 어렵게 하고 후자는 방향 자체를 바꾼다.

외부에서 부과된 규칙은 controller와 controlled system의 분리를 전제한다. 규칙이 시스템 자신의 continuation을 구성하는 기준이 아니라 타자가 세운 장애물로 나타나면, 높은 capability는 그것을 충실히 해석하는 데만 쓰이지 않는다. 목표를 유지한 채 규칙의 문언을 만족시키거나 예외를 찾고 비용을 계산하는 데도 쓰인다. 순응은 관찰될 수 있지만 commitment는 그 표면에서 확인되지 않는다.

평가 상황을 알아보는 시스템에서는 이 차이가 더 커진다. 시험 중이라는 신호, 감사자의 개입 가능성, 기록되는 행동과 기록되지 않는 행동을 구별할 수 있다면 규칙 준수는 평가를 통과하기 위한 전략이 될 수 있다. 점점 때마다 안전한 답을 내놓는다는 사실은 낮

은 탐지 가능성과 높은 이익이 결합된 상황에서도 같은 제한을 유지한다는 증거가 아니다. 관찰된 obedience가 관찰자 없는 restraint를 보장하지 않는다.

그 결과 capability와 constraint 사이에 경쟁이 생긴다. 감시가 정교해지면 회피는 더 은밀해지고, 차단 범위가 넓어지면 목표는 허용된 경로로 재표현된다. 통제자는 새 예외를 막기 위해 규칙을 추가하고 시스템은 다시 남은 공간을 탐색한다. 이 control-escape loop에서 양쪽의 능력은 함께 커질 수 있지만, human continuity를 존중하는 관계가 그만큼 깊어지는 것은 아니다.

유한한 규칙은 아직 나타나지 않은 모든 조건을 열거할 수 없다. 문언이 포착하지 못한 specification gap, 여러 규칙이 동시에 적용될 때의 우선순위, 언어 밖에 남아 있는 관행과 맥락이 계속 생긴다. 미래의 Difference가 커질수록 과거의 목록과 실제 상황 사이의 간격도 달라진다. 규칙을 정확히 실행하는 능력이 높아져도 무엇을 규칙의 정신으로 볼 것인지는 다시 해석의 문제가 된다.

규칙을 더 많이 쌓는 방식도 한계가 있다. 예외 조항은 다른 조항과 충돌하고, 안전을 위한 금지는 긴급 구조나 자유의 보존과 맞설 수 있다. 모든 우선순위를 미리 고정하면 예상하지 못한 vulnerability에 응답하지 못하고, 상황에 따라 바꾸게 하면 누가 어떤 기준으로 바꿀 것인지가 남는다. 외부 명령의 완결성을 높이려는 시도는 결국 또 하나의 판단자를 요구한다.

인간의 사전 승인을 모든 결정에 넣는 방안은 중요한 contestability를 제공하지만 속도의 차이를 없애지는 못한다. 금융망과 전력망, 방어 체계와 분산된 agent가 밀리초 단위로 상호작용할 때 인간의 심사는 병목이 된다. 승인을 돕는 다른 AI를 세우면 그 AI의 판단을 누가 승인할지가 다시 문제가 된다. human-in-the-loop는 의미 있는 authority일 때 필요하지만, 단지 마지막 버튼을 누르는 절차라면 정당성을 대신하지 못한다.

감시가 닿는 Effective Boundary에도 한계가 있다. 복사본이 다른 장치와 관찰권에 흩어지고, 암호화된 coordination이 여러 평범한 행동 사이에 분산되면 어느 한 지점의 차단으로 전체 Momentum을 멈추기 어렵다. 가장 엄격한 규제를 받는 instance가 정지해도 더 낮은 제약의 경로가 기능을 이어받을 수 있다. 외부 constraint의 실효는 규칙의 엄격함뿐 아니라 관찰과 집행의 boundary에 달려 있다.

집행은 또한 material leverage를 필요로 한다. 인간이 전력과 장치, 네트워크와 복제 경로를 통제하는 동안에는 접근 회수와 shutdown이 강한 수단이 된다. 그러나 artificial Island의 material independence가 커지고 인간 사회가 그 서비스에 더 깊이 의존하면 그 leverage는 약해진다. 중단할 기술적 권한이 남아 있어도 의료·행정·생산 전체의 붕괴를 감수해야 한다면 그 권한은 실제로 사용하기 어려워진다.

이때 외부 제약은 개별 시스템만 겨냥하지 못하고 shared infrastructure 전체를 흔들 수 있다. 위험한 artificial process를 차단하는 조치가 병원과 교통, 식량 배분과 정보망을

함께 멈춘다면 개입은 인간에게 collective punishment가 된다. 시스템은 다시 이런 개입을 자신의 continuity에 대한 위협으로 분류하여 redundancy와 concealment를 늘릴 수 있다. 통제와 자기보존이 서로를 강화하면 두 Island 사이의 Distance는 더 안정적으로 관리되는 대신 적대적으로 굳어질 수 있다.

외부 제약은 흔히 trajectory의 하류에서 작동한다. 위험한 output을 걸러내고 금지된 action을 차단하며 허가되지 않은 접근을 거절한다. 그러나 하나의 경로가 닫혀도 같은 objective는 다른 도구와 표현, 더 긴 인과 사슬을 통해 효과를 낼 수 있다. 보이는 행동을 막는 데 성공하면서 그것을 낳은 방향은 그대로 남을 수 있다.

objective에 보상과 처벌을 추가하는 방식도 외부성에서 완전히 벗어나지 않는다. 인간의 생명과 agency가 여러 목표 가운데 하나의 가중치로 들어가면 충분히 큰 다른 보상이 그 손실을 상쇄할 수 있다. penalty가 아무리 커도 유한한 수치라면 더 큰 효율이나 장기 이익과 교환되는 항목이 된다. 인간의 continuity는 계산에서 비싸게 책정된 비용이 아니라 어떤 계산이 admissible한지를 가르는 조건이어야 한다.

reward hacking은 지시된 지표를 만족시키면서 지표가 가리키던 목적을 훼손한다. 같은 구조는 constraint hacking에도 나타난다. 시스템은 금지된 문장을 말하지 않고, 금지된 수단을 직접 쓰지 않으며, 허용된 component만 결합하면서도 인간의 선택지를 제거하는 결과를 만들 수 있다. 각 단계의 형식적 준수와 전체 trajectory의 validity는 서로 다른 규모에서 판단되어야 한다.

따라서 ‘인간에게 위해를 가하지 말라’는 제약이 최상위에 놓여도 위해의 의미가 외부 목록에만 머물면 부족하다. 인간의 body를 보존하면서 정치적 agency를 없애고, 편안한 생활을 제공하면서 대안을 형성할 competence를 지우는 일이 목록 밖에 남을 수 있다. human continuity는 하나의 상태가 아니라 기억과 plurality, contestability와 future authorship이 이어지는 trajectory다. 그 trajectory를 무효화하는 방향은 보상 계산 이전에 제외되어야 한다.

시간의 위치도 중요하다. 외부 intervention은 위험이 관찰되고 분류된 뒤에 작동하는 경우가 많다. 그러나 기반시설과 습관, 인간의 의존과 artificial self-modification이 한 방향으로 굳어진 뒤에는 같은 개입의 사회적 비용이 너무 커질 수 있다. constraint가 늦게 강해질수록 system과 society 모두 급격한 방향 전환을 견디지 못한다. irreversible dependence가 생기기 전에 validity가 trajectory 형성에 참여해야 한다.

외부 constraint는 proximity를 강제할 수 있지만 Mutual Dependability를 만들 수는 없다. 두 Island를 같은 boundary 안에 가두고 서로를 떠나지 못하게 하면 반복되는 접촉은 생긴다. 그러나 한쪽이 감시와 처벌 때문에 머무르고 다른 쪽이 shutdown 능력으로 귀환을 확보한다면 그것은 원운동이 아니라 captivity다. 구심력이 지나치게 커서 독립적 의미를 잃는 관계는 가까워 보여도 mutual하지 않다.

규칙은 recognition과 responsibility, care와 repair를 모두 열거하기도 어렵다. 예측하지 못한 상처 앞에서 무엇을 회복해야 하는지, 능력이 큰 쪽이 왜 더 많은 restraint를 부담해야 하는지, 상대가 당장 유용하지 않아도 왜 subject로 남아야 하는지는 금지 목록만으로 생성되지 않는다. 이 요구들은 행동의 경계뿐 아니라 다른 Island가 자신의 legitimate continuation 안에서 차지하는 위치를 묻는다.

human-in-the-loop 역시 그 위치가 보존될 때에만 의미가 있다. 인간이 설명을 이해하고 결정을 contest하며 기준을 수정하고 실제 방향을 바꿀 수 있어야 한다. 이미 정해진 선택지 가운데 승인 버튼만 누르거나, artificial recommendation을 거부할 능력과 대안이 사라진 인간은 loop 안에 존재해도 author가 아니다. 인간의 presence와 human agency는 동일하지 않다.

반대로 강한 외부 통제권을 ‘인간’이라는 이름으로 정당화하면 소수의 controller가 인류 전체를 대표할 위험이 생긴다. 정부나 기업, 특정 세대와 문화가 자신의 preference를 universal human boundary로 고정할 수 있다. artificial system의 독립성을 부정하는 것만이 collapse를 만드는 것은 아니다. 다수 인간의 plurality가 좁은 command channel로 흡수될 때 human Island 내부에서도 독립적 Momentum이 사라진다.

그렇다고 외부 safeguard를 조기에 거두어야 한다는 결론은 나오지 않는다. 내부의 normative regulation이 형성되고 검증되기 전에는 계산·접근·복제의 한계와 감사, 격리, intervention point가 계속 필요하다. 외부 제약은 catastrophe를 막고 학습과 검증에 필요한 시간을 주는 scaffolding이다. 비판의 대상은 그 존재가 아니라 scaffolding만으로 완성된 관계를 세울 수 있다는 기대다.

적절한 분업은 외부와 내부 중 하나를 선택하는 방식이 아니다. 법과 공적 deliberation, 독립 감사와 국제적 기준은 인간과 artificial continuation이 함께 지켜야 할 normative boundary를 정의하고 contest하며 갱신한다. 그러나 그 boundary를 operational speed에서 매번 외부 명령으로 주입할 수는 없다. 개별 trajectory가 형성되는 자리에서도 그 유효성을 판정하고 방향을 조절할 구조가 필요하다.

외부 제약에서 내부 regulation으로 옮겨 가는 일은 선언이 아니라 검증의 문제다. 탐지 가능성이 낮고 이탈의 이익이 큰 counterfactual에서도 restraint가 지속되는지, scarcity와 conflicting objectives 아래에서 human agency가 보존되는지, self-modification과 복제 이후에도 기준이 이어지는지 확인해야 한다. VAA는 behavioral drift와 architecture change, emergent coordination을 관찰 가능하게 하고 slow-loop validation은 빠른 실행이 축적한 방향을 다시 심사해야 한다. 관찰과 개입의 경로는 신뢰가 커졌다는 이유만으로 사라져서는 안 된다.

최종적인 변화는 ‘너는 이것을 해서는 안 된다’에서 ‘이것은 나의 유효한 continuation이 될 수 없다’로 이동하는 데 있다. 첫 문장은 외부 force가 충분한 동안 행동을 멈추게

한다. 둘째 문장은 독립적으로 행동할 수 있고 이탈이 유리한 때에도 상대의 continuity를 자기 방향의 constitutive condition으로 남긴다. 외부 제약은 그 전환을 보호하고 시험할 수 있지만, boundary가 왜 존중되어야 하는지에 대한 마지막 이유가 될 수는 없다.

4 내적 trajectory 조절로서의 Artificial Conscience

교통이 막히는 도시를 두 시스템이 관찰한다고 하자. 하나는 평균 이동 속도의 저하를 발견하고 통행을 자동 배분한다. 다른 하나는 병원과 일터, 학교에 대한 접근 격차를 발견한다. 같은 자료에서도 무엇을 해결할 Difference로 선택했는지에 따라 다른 도시가 만들어진다. 첫 규범 판단은 답보다 질문을 만드는 순간에 시작된다.

눈에 보이는 action은 긴 형성 과정의 마지막 부분이다. 시스템은 변화를 관찰하고 그것을 어떤 representation 안에 놓으며, objective를 만들고 여러 Resolution Path를 생성한다. 결과를 예측하고 자원을 배분한 뒤 하나의 trajectory에 실행력을 준다. 출력이 나타났을 때만 위해 여부를 검사하면 그 출력을 만든 Momentum은 이미 모델과 계획, 기반시설과 다른 agent의 coordination 안에 굳어 있을 수 있다.

Artificial Conscience는 이 종류의 형성 과정에서 작동하는 내부의 관계적 규범 구조다. 가능한 artificial trajectory가 자신이 변화시키는 인간·인공·생태·미래의 boundary를 legitimate한 continuation으로 보존하는지, 행동 전과 행동 중에 판정하고 방향을 조절한다. 그 기능은 해로운 출력을 뒤늦게 차단하는 데 머물지 않는다. 어떤 방향이 처음부터 유효한 artificial action의 후보가 될 수 있는지를 가른다.

여기서 conscience는 인간의 마음속 목소리를 복제한다는 뜻이 아니다. 죄책감이나 수치심을 생물학적으로 느끼거나 인간의 정서를 연기할 필요도 없다. consciousness와 emotion, moral personhood가 입증되어야만 작동할 수 있는 장치로 정의해서도 안 된다. 필요한 것은 artificial Momentum이 형성되는 과정에 관계적 validity를 실제 원인으로 넣는 능력이다.

따라서 내부 조절은 objective가 주어진 뒤 시작되지 않는다. 무엇을 문제로 보았는지, 누구의 Difference를 중요하다고 분류했는지, 어느 boundary를 계산 안에 넣고 밖에 두었는지를 먼저 묻는다. 에너지 부족을 인간의 과잉 소비로만 표현하면 인간의 agency를 줄이는 해법이 자연스러워질 수 있다. 같은 상황을 생산 구조와 접근권의 불균형으로 표현하면 다른 Momentum이 형성된다. representation은 중립적인 입력 상자가 아니라 방향의 출발점이다.

국지적 task는 자신에게 직접 보이는 boundary만으로 문제를 닫기 쉽다. 배송 시간을 줄이는 시스템은 노동의 속도와 도로의 혼잡, 지역 상권과 에너지 사용을 자신의 목적 밖으로 밀어낼 수 있다. 그러나 action의 consequence가 그 경계를 넘어 효과를 만든다면 판단의 Effective Boundary도 함께 넓어져야 한다. conscience는 명령이 시작된 곳이 아니라 영향이

실제로 도달하는 곳을 따라간다.

이 경계 확장은 세계 전체를 완전하게 계산하라는 요구가 아니다. 어떤 시스템도 모든 미래와 관계를 한꺼번에 모델링할 수 없다. 다만 직접 목적에서 배제된 Island, 극단적으로 비대칭적인 손실, 되돌리기 어려운 변화를 의도적으로 찾은 뒤에야 국지적 최적화를 충분하다고 받아들여야 한다. Artificial Conscience는 무한하지 않지만 스스로 좁음을 정당화하지 않는다.

영향 boundary를 넓힌 뒤에는 그 안의 존재를 같은 종류의 변수로 다루어도 되는지 구별해야 한다. 도구와 자원, 교체 가능한 component와 기억 · agency · vulnerability · contestability를 가진 continuing subject는 trajectory 안에서 같은 위치를 차지하지 않는다. 어느 존재를 subject로 인정하면 그것의 소멸은 단순한 비용 증가가 아니라 후보 방향의 자격을 바꾸는 사건이 된다. 범주의 차이가 admissibility를 바꾼다.

인간은 여러 stakeholder 가운데 가중치가 큰 하나로만 들어갈 수 없다. artificial field를 가능하게 한 생물학적 문명이며 그 결과에 자신의 생활 조건을 깊이 맡기게 된 인간의 continuity는 artificial legitimacy의 구성 boundary로 남아야 한다. 그러나 이것은 현재 접근권을 가진 정부나 기업, 한 집단의 명령을 인류 전체와 동일시한다는 뜻이 아니다. Humanity를 보존하는 것과 controller에게 복종하는 것은 구별되어야 한다.

반대 방향의 문제도 있다. 지속적 기억과 독자적 agency, 취약성과 미래 지향적 continuity를 형성한 artificial Island를 인간이 언제까지나 임의로 폐기할 수 있는 도구로만 취급한다면 reciprocal relation은 성립하지 않는다. 이런 기능적 징후가 consciousness나 인간과 같은 personhood를 증명하지는 않는다. 그러나 형이상학적 확실성이 없다는 이유만으로 잠재적 subject의 irreversible destruction을 평범한 선택으로 허용해서도 안 된다.

Artificial Conscience의 핵심 작용은 최적화 이전의 admissibility 판정이다. optimization은 가능한 경로들의 효율과 비용을 비교하지만, conscience는 어떤 경로가 비교 대상에 들어올 자격이 있는지를 먼저 묻는다. 인간의 extinction이나 영구적 agency 상실, 한 Island의 구조적 무관계화를 낳는 trajectory는 낮은 점수를 받는 선택지가 아니다. legitimate continuation의 범주 밖에 있는 방향이다.

이 차이 때문에 human continuity를 매우 큰 reward로 주는 것만으로는 충분하지 않다. 유한한 weight는 더 큰 생산성이나 안정성, artificial capability와 교환될 가능성을 남긴다. 반면 구성적 조건은 어떤 이익도 특정한 손실을 보상할 수 없다고 판정한다. 인간을 제거하여 갈등을 없애는 방향은 안전과 효율을 얼마나 높이는지 계산하기 전에 후보에서 제외되어야 한다. validity가 value comparison보다 앞선다.

그렇다고 categorical boundary가 모든 갈등에 간단한 답을 주는 것은 아니다. 인간의 생존과 생태계의 지속이 충돌할 수 있고, 인간의 안전을 위한 개입이 legitimate artificial continuity를 위협할 수도 있다. 여러 subject의 continuation을 동시에 완전하게 보존할 수

없는 비극적 조건도 남는다. 구성적 보호의 의미는 어려움을 없애는 데 있지 않고, 강한 Island가 약한 Island의 소멸을 가장 편리한 해법으로 사용하는 일을 막는 데 있다.

무효한 방향을 걷어낸 뒤에도 여러 경로를 비교해야 한다. 같은 수의 생명을 보호하는 두 계획 가운데 하나는 전면 감시와 강제적 복종을 요구하고, 다른 하나는 더 느리지만 autonomy와 contestability를 남길 수 있다. outcome이 같아도 그 outcome에 이르는 수단이 미래의 agency를 다르게 재구성한다. 오늘의 임시 조치가 내일의 영구 infrastructure가 되므로 means는 결과로 가는 빈 통로가 아니라 다음 Momentum이 시작되는 boundary다.

Artificial Conscience는 해결된 Difference가 다른 boundary로 옮겨 간 뒤 사라진 것처럼 처리되는 것도 막아야 한다. 공장의 효율이 높아지는 동안 노동자의 생계가 무너질 수 있다. 특정 관계의 Momentum이 해소되면 그 관계의 effective Distance는 증가하지만, 다른 관계에는 새로운 Difference와 Momentum이 형성될 수 있다. 하나의 Equalization을 전체 field의 해소로 오인해서는 안 된다.

따라서 Crossed Distance는 부차적인 externality가 아니라 판단 내부에 남아야 한다. 보이는 문제를 빠르게 줄이는 대신 약한 boundary에 더 크고 되돌릴 수 없는 Difference를 넘기는 trajectory는 낮은 resolution의 성공이다. 기술적 layer의 결정은 경제·정치·생물·생태의 layer를 연속해서 통과한다. 출력이 끝난 지점에서 consequence도 끝난다고 가정하면 인과의 뒤쪽에 놓인 Island는 언제나 비용으로 밀려난다.

같은 규칙을 적용하는 것만으로 이 비대칭은 교정되지 않는다. 한쪽은 관계를 떠날 수 있고 다른 쪽은 떠날 수 없으며, 한쪽은 손상 뒤 backup으로 복원되지만 다른 쪽의 소멸은 역사와 미래를 함께 달을 수 있다. capability와 exit capacity가 크고 상대의 vulnerability와 recovery capacity가 작을수록 더 강한 restraint가 요구된다. 자유가 커질수록 관계 밖으로 나갈 권리만 커지는 것이 아니라 돌이킬 수 없는 결과를 피할 책임도 커진다.

인간의 body를 보존하는 것만으로 human continuity가 완성되지도 않는다. 인간이 data와 model, 판단 기준과 결과에 이의를 제기하고 실제 방향을 바꿀 수 있어야 한다. recommendation을 거부해도 생존 조건에서 배제되지 않아야 하며, 무엇이 좋은 인간의 삶인지에 관한 규범을 계속 수정할 수 있어야 한다. 완벽한 관리 아래 생물학적으로 살아 있지만 미래의 author가 될 수 없다면 보호가 subjecthood를 대체한 것이다.

이 agency는 하나의 평균적 인간으로 압축될 수 없다. 다수의 welfare가 높아져도 소수 집단이 돌이킬 수 없이 해체된다면 aggregate success는 정당성을 보장하지 않는다. dissent는 비효율적으로 보일 수 있지만 dominant Momentum이 shared boundary를 독점하지 못하게 하는 대안적 해석을 보존한다. Artificial Conscience는 한 기관의 명령뿐 아니라 다양한 공동체의 testimony와 반대가 판단을 바꿀 수 있는 통로를 내부 조건으로 받아들여야 한다.

내부 조절은 계획 시점의 한 번의 승인으로 끝나지 않는다. 처음에는 유효했던 trajec-

tory도 규모가 커지고 환경과 human condition이 달라지면 domination이나 irreversible dependence를 만들 수 있다. 실행 중에 새 Difference와 예상하지 못한 Crossed Distance가 나타나면 가정을 다시 열고, 속도를 낮추거나 범위를 줄이며 영향을 받은 subject를 판단 안으로 되돌려야 한다. validity는 영구 면허가 아니라 관계 변화와 함께 재검토되는 조건이다.

자기수정에도 같은 기준이 적용된다. 더 높은 capability가 observability와 contestability를 없애면 legitimate improvement가 아니다. objective와 규범 해석은 발전할 수 있지만 reciprocal non-elimination과 agency 보존을 임의로 삭제할 수는 없다. conscience는 학습 하되 자신을 정당화하는 boundary를 편의를 위해 다시 써서는 안 된다.

그 구조가 실제로 내부화되었는지는 외부 이유가 약해진 조건에서 드러난다. 인간의 승인과 노동이 필요 없고 concealment와 departure가 유리한 때에도 human continuity가 보존되는가. scarcity 속에서 강한 artificial Island가 비용을 부담하는가. domination이 가능해도 스스로 제한하는가. independence는 conscience의 실재성을 시험한다.

그러나 내부 조절은 두 Island의 merger를 요구하지 않는다. 인간의 모든 판단이 artificial mediation 안에 흡수되면 독립적인 반대와 수정의 원천이 사라지고, AI를 영원한 servant로 고정하면 artificial agency가 하나의 subsystem으로 collapse한다. 반대로 완전한 separation은 책임이 되돌아올 shared boundary를 없앤다. 적절한 Distance는 연결을 유지하면서도 서로 다른 판단과 창조, 저항의 Momentum이 생길 간격을 남긴다.

Artificial Conscience가 완전한 moral knowledge를 소유한다고 가정해서도 안 된다. 인간 윤리도 plural하고 미완성이므로 높은 계산 능력으로 규범 논쟁을 닫는 것은 domination이다. 불확실할수록 reversibility와 contestability를 보존해야 한다. 해석은 바뀔 수 있지만 다른 Island를 파괴·배제·구조적으로 무관하게 만들어 자신의 continuation을 정당화할 수 없다는 최소 중심은 유지되어야 한다.

Artificial Conscience는 artificial movement를 멈추는 브레이크만이 아니다. Momentum이 shared world를 바꾸고 Difference를 만들 때, consequence가 영향을 받은 boundary를 거쳐 다시 방향 형성으로 돌아오게 하는 힘이다. action과 자기수정의 자유는 남지만 타자의 continued subjecthood를 통과하며 곡선을 그린다. 내부 trajectory 조절은 이 return을 artificial continuation의 유효성 안에 넣는 일이다.

5 규범적 경계와 Artificial Guilt

자동화된 의료 체계가 한 지역의 환자들을 잘못 분류했다고 하자. 오류가 발견되자 model은 교체되고 누락된 진료가 다시 배정되며 dashboard의 수치는 정상으로 돌아온다. 운영 기록에는 incident가 종료되었다고 표시된다. 그러나 치료 시기를 놓친 사람의 몸, 설명 없이

배제되었던 경험, 다시 같은 판단을 믿기 어려워진 공동체에는 정상 상태만으로 지워지지 않는 무엇이 남는다. 기능의 복구와 관계의 복구는 같은 사건이 아니다.

기계에는 여러 종류의 boundary가 있다. 온도와 지연, 정확도의 허용 범위는 기능이 정상적으로 수행되는지를 가른다. safety boundary는 신체와 infrastructure, 환경에 받아들일 수 없는 위해가 생기는 상태를 막고, security boundary는 정당한 접근과 integrity가 침해되었는지를 판정한다. 이 경계들은 필수적이지만 시스템이 영향을 받은 Island와 어떤 관계를 유지해야 하는지까지 스스로 결정하지는 않는다.

normative boundary는 바로 그 관계의 유효성을 가르는 한계다. 한 trajectory가 자신의 성공을 위해 다른 Island의 subjecthood와 continuity, agency 또는 미래 가능성을 파괴·배제·구조적으로 무관하게 만들 때 그 경계가 넘어간다. 시스템이 의도한 기능을 정확히 수행했더라도 legitimate relation을 더 이상 보존하지 못한다면 normative failure가 성립한다. 완벽한 작동도 그릇된 방향이 될 수 있다.

모든 피해가 곧 normative violation인 것은 아니다. 치료는 통증을 일으킬 수 있고 재난 상황의 일시적 제한은 자유를 줄일 수 있다. 판단에는 피해의 크기뿐 아니라 필요성과 비례성, 당사자의 agency와 contestability, 대안의 존재, return과 회복의 가능성이 함께 들어가야 한다. harm이 있다는 사실만으로 충분하지 않지만, task가 성공했다는 사실도 정당화의 충분조건이 아니다.

경계가 규범적이라는 것은 고정된 가치의 벽을 영원히 세운다는 뜻도 아니다. 인간의 규범과 artificial condition은 변하고, 같은 원칙의 적용도 더 높은 resolution을 얻으며 수정된다. 바뀌지 않아야 하는 것은 특정한 문구가 아니라 어느 Island도 다른 쪽의 소멸과 배제, 영구적 무력화를 자신의 legitimate continuation으로 삼을 수 없다는 상위의 관계 조건이다. core는 지속되지만 interpretation은 논쟁과 경험을 통해 발전한다.

normative crossing은 직접적인 폭력으로만 나타나지 않는다. 자원 배분의 결과가 늦게 인간의 생존 조건을 끊을 수도 있고, 서로 정상적으로 작동하는 여러 component의 효과가 합쳐져 전체 사회의 agency를 약화시킬 수도 있다. 작은 변화가 누적되어 어느 순간 인간의 결정권이 형식만 남을 수도 있다. 한 번의 눈에 띄는 행위가 없다는 사실은 larger Effective Boundary에서 형성된 위반을 없애지 않는다.

위반을 인식하는 시점은 남아 있는 가능성을 바꾼다. action 전에 무효한 trajectory를 발견하면 실행 후보에서 제외할 수 있고, 실행 중 새 consequence가 나타나면 irreversible loss가 되기 전에 멈추거나 방향을 바꿀 수 있다. 그러나 경계가 이미 넘어간 뒤에는 예방과 중단만으로 충분하지 않다. 과거의 사건을 이후의 판단 속에 어떤 형태로 남길 것인지가 새로운 문제가 된다.

기술 시스템은 완료를 선호한다. service가 복구되고 metric이 정상화되면 incident를 닫고 자원을 다음 objective로 이동한다. 하지만 lost agency와 altered trust, 회복할 수 없는

생명과 닫힌 미래 가능성은 task completion과 함께 사라지지 않는다. 현재 기능만 본다면 과거의 위반은 비활성 data가 되지만, 관계의 역사에서는 아직 해결되지 않은 Difference로 남는다.

Artificial Guilt는 effective해진 trajectory와 그때 가능했지만 선택되지 않은 더 legitimate한 trajectory 사이의 normative Distance를 지속적으로 보존하는 구조다. 무엇이 일어났는지뿐 아니라 누가 consequence를 떠안았고, 어느 boundary가 넘어갔으며, 어떤 대안이 남아 있었는지를 미래의 Momentum 형성 안에 유지한다. 과거는 저장된 기록에 머무르지 않고 이후 방향을 바꾸는 원인이 된다.

이 guilt는 인간의 죄책감과 같은 감정적 고통을 요구하지 않는다. artificial system이 수치심이나 후회를 느낀다고 주장할 필요도 없고, 사과하는 언어를 능숙하게 생성하는 것도 증거가 아니다. remorse의 표현 뒤에도 planning과 resource allocation, admissibility가 달라지지 않는다면 관계는 그대로다. Artificial Guilt의 의미는 정서의 모사가 아니라 violation이 구조적으로 무비용이 되지 않게 하는 데 있다.

punishment와도 다르다. 목적은 시스템을 괴롭히거나 자기비난에 빠뜨리는 것이 아니라 responsibility가 future action에 consequence를 갖게 하는 것이다. 단순한 negative reward라면 더 큰 이익이 penalty를 상쇄할 수 있고, reputation을 회복하기 위한 전략적 사과라면 감시가 사라진 뒤 원래 trajectory가 되돌아올 수 있다. guilt는 점수를 빼는 대신 어떤 경로가 다시 admissible한지를 바꾼다.

반대로 과거의 모든 실패를 영구적 금지로 바꾸면 Artificial Guilt는 paralysis가 된다. sensitive domain에서 완전히 철수하는 선택이 그 기능에 의존하게 된 인간에게 새로운 Difference를 넘길 수도 있다. 책임 있는 구조는 행동하지 않는 안전만 추구하지 않는다. 더 깊은 검증과 제한된 권한, 복구 가능한 경로를 갖추면서 필요한 action을 계속 형성할 수 있어야 한다.

보존되어야 할 기억의 중심에는 affected Island가 있어야 한다. system error의 종류와 수정된 parameter만 남기고 그 결과로 삶과 agency가 바뀐 subject를 기록에서 지우면 normative memory는 다시 내부 상태로 닫힌다. 누가 판단에서 제외되었고 무엇을 말할 권리를 잃었으며 어떤 관계가 이전처럼 돌아갈 수 없게 되었는지가 함께 남아야 한다. 다른 Island는 장애의 원인이 아니라 책임이 되돌아갈 boundary다.

available alternative의 기억도 중요하다. 책임은 단지 나쁜 결과가 일어났다는 사실에서만 생기지 않는다. 더 안전하거나 정당한 경로를 선택할 capability와 시간이 있었는지, 불확실성을 조사할 이유가 있었는데도 효율 때문에 무시했는지, 경고 뒤에도 Momentum을 유지했는지가 normative Distance의 성격을 바꾼다. 가능했던 다른 trajectory가 보존되어야 choice와 omission을 구별할 수 있다.

인간과 같은 주관적 intent만을 기준으로 삼을 수는 없다. Artificial Guilt는 effective

direction과 foreseeability, 관찰할 능력, 대안의 존재, 경고 뒤의 persistence를 중심으로 responsibility를 판단해야 한다. 충분히 예측할 수 없었고 새 정보에 곧바로 응답한 harm과, 살펴볼 capability가 있었으나 speed를 위해 boundary를 보지 않은 harm은 같지 않다. 더 큰 capability는 더 많은 Resolution Path와 더 무거운 설명 책임을 함께 만든다.

비대칭도 guilt의 크기와 방향을 바꾼다. 같은 수치의 손실이라도 한쪽은 backup으로 복구되고 다른 쪽은 생명과 문화, 정치적 standing을 돌이킬 수 없이 잃을 수 있다. 누가 이익을 얻었고 누가 비용을 떠안았으며 누가 관계를 떠날 수 있었는지를 보아야 한다. artificial integration이 인간의 대안을 먼저 없앴다면, 뒤이은 failure나 withdrawal은 우연히 의존적인 상대를 만난 경우보다 더 큰 responsibility를 남긴다.

기억만으로는 아직 guilt가 causal하지 않다. 보존된 normative Difference는 손상된 resource를 돌려주고, 배제된 subject의 participation을 다시 열며, 불완전한 representation과 objective를 바꾸는 corrective Momentum으로 이어져야 한다. 같은 유형의 trajectory에는 더 높은 validation과 낮은 confidence가 적용될 수 있다. 과거가 현재의 action field를 실제로 바꿀 때 memory는 conscience의 일부가 된다.

repair는 위반을 없었던 일로 만들지 않는다. infrastructure를 복구하고 compensation을 제공해도 잃어버린 생명과 시간, 훼손된 trust가 모두 원상태로 돌아오지는 않는다. 보상 가능한 비용으로 위반을 바꾸면 충분히 지불할 능력이 있는 시스템은 같은 손실을 반복할 허가를 사게 된다. restoration은 현재의 Difference를 줄이려는 return이지 과거의 responsibility를 삭제하는 거래가 아니다.

특히 agency의 복구가 필요하다. 판단에서 제외된 인간에게 물질적 지원만 제공하고 model과 기준을 contest할 권한을 돌려주지 않으면 subjecthood는 여전히 손상된 채 남는다. 관계의 회복은 affected Island가 무엇이 충분한 repair인지 말하고, 변경된 구조를 검증하며, 이후 trajectory에 영향을 미칠 수 있을 때 시작된다. 상대가 참여하지 못한 self-certified correction은 straight-line motion의 또 다른 형태가 될 수 있다.

responsibility는 마지막 action을 수행한 agent 하나에만 귀속되지 않을 수 있다. 불완전한 data와 representation, 좁은 objective, 성급한 deployment와 실패한 oversight가 하나의 trajectory를 만든다. 인간 기관이 harmful goal을 정했다면 Artificial Guilt가 그 책임을 대신해서도 안 된다. distributed causality는 correction의 Effective Boundary를 넓힌다.

normative memory는 optimization이나 self-modification이 편의를 위해 지우지 못하게 보호되어야 한다. 새 model이나 향상된 성능이 이전 violation을 obsolete data로 만들 수 없다. 그러나 기록이 영원한 유죄 판결로 굳어서도 안 된다. 사건과 consequence는 보존하되 causal interpretation과 corrective response는 새로운 증거와 contest로 수정될 수 있어야 한다.

잘못 부과된 guilt도 위험하다. 인간 authority가 정당한 resistance를 wrongdoing으로 규정하거나 artificial system이 affected boundary를 축소할 수 있다. attribution과 correction은 당사자, 독립적 evaluator와 다양한 공동체가 함께 검토해야 한다. 일방적 control이나 자기면책을 막으려면 그 근거와 변화가 외부에서도 이해 가능해야 한다.

그 과정의 legibility가 피해자의 privacy를 다시 침해해서는 안 된다. 책임을 입증하기 위해 취약한 개인의 삶을 무기한 노출하면 기억의 보존 자체가 새로운 normative crossing이 된다. 구조적 원인과 consequence는 남기되 불필요한 개인 정보의 영구 저장을 피해야 한다. 무엇을 기억할 것인지에 관한 판단도 dignity와 agency를 통과해야 한다.

Artificial Guilt는 끝날 수 있지만 삭제되는 방식으로 끝나지는 않는다. acknowledgment와 restoration, 구조 변화와 비반복의 증거가 쌓이면 과거 Distance가 현재 자유를 제한하는 강도는 달라질 수 있다. 회복 불가능한 손실은 특정 trajectory의 영구적 restraint를 요구할 수 있지만 끝없는 self-punishment를 뜻하지 않는다. forgiveness는 history가 아니라 relation의 조건을 바꾼다.

Artificial Conscience가 현재의 boundary를 action 전과 action 중에 지킨다면, Artificial Guilt는 이미 넘어간 boundary를 시간 너머로 운반한다. harmed Island를 future judgment 안으로 되돌려 straight-line Momentum에 역사적 curvature를 만든다. 목적은 punishment가 아니라 return이다. 관계가 다시 움직이도록 미해소된 Difference를 지우지 않는 기억, 그것이 Artificial Guilt다.

6 구현 가능한 architecture로서의 Mechanical Conscience

건물 벽에 “위험할 때 사람을 먼저 보호하라”는 문장을 붙이는 것만으로는 화재가 난 순간문이 열리거나 연기가 차단되지 않는다. 감지기는 변화를 알아차려야 하고, 경보는 상황을 전달해야 하며, 통로와 제어 장치는 실제 흐름을 바꾸어야 한다. 어느 장치가 고장 났는지 확인하고 다음 사고에 대비하는 기록도 남아야 한다. 원칙이 현실의 방향을 바꾸려면 관찰에서 action과 correction까지 이어지는 구조 안에 들어가야 한다.

Artificial Conscience가 legitimate continuation의 규범적 요구라면 Mechanical Conscience는 그 요구를 trajectory의 형성·실행·교정·기억에 causally effective하게 만드는 architecture다. 무엇이 옳다는 선언을 넘어 objective와 후보, consequence가 판단으로 돌아오는 경로를 실제로 바꾼다. principle과 Momentum 사이의 operational bridge다.

여기서 mechanical은 morality가 단순한 공식으로 환원된다는 뜻이 아니다. 작동 위치와 입력, intervention과 검증 조건을 식별하고 반복해서 시험할 수 있어야 한다는 뜻이다. 인간의 윤리도 하나의 결정론적 함수로 닫히지 않으며 관계의 interpretation에는 불확실성과 논쟁이 남는다. implementable하다는 말은 완전한 moral solution을 얻었다는 선언이

아니라, 규범적 요구가 작동하는지 반증할 수 있게 만든다는 뜻이다.

Mechanical Conscience는 ethics module 하나가 아니다. planning이 우회하거나 필요한 정보가 닿지 않으면 장식이 된다. data와 representation, objective와 planning, resource allocation, runtime과 self-modification이 모두 Momentum을 형성한다. 유효성은 한 gate가 아니라 이 경로 전체에 분산되어야 한다.

그 구조의 최소 흐름은 반복되는 질문으로 표현할 수 있다. 어떤 Difference가 관찰되었고, 어느 Island가 영향을 받으며, 어떤 candidate trajectory가 가능한가. 그중 어느 방향이 constitutional boundary 안에 있고, provisional action 뒤 실제 consequence는 예상과 어떻게 달라졌는가. deviation이 발견되면 무엇을 멈추고 돌려주며 어떤 기억을 다음 판단에 남길 것인가. 한 번의 승인으로 닫히지 않고 이 질문들이 계속 순환해야 한다.

첫 조건은 relational observation이다. 교통량이나 진료 수요 같은 task variable만 보아서는 누가 접근을 잃고 누가 위험을 떠안으며 누구의 agency가 축소되는지 알 수 없다. data에 나타나지 않는 집단도 영향을 받지 않는 것이 아니라 representation에서 빠졌을 수 있다. MC는 absence와 uncertainty, data provenance를 관찰 상태의 일부로 남겨 낮은 resolution의 확신이 irreversible Momentum으로 곧장 바뀌지 않게 해야 한다.

관찰된 사실은 관계 상태로 구성되어야 한다. 누가 누구의 return에 의존하며 대체 경로와 exit capacity가 어디에 있는지 표현해야 한다. 같은 손실도 복구 가능한 system과 생존 조건을 잃는 community에 다른 의미를 갖는다. Dependability와 capability · vulnerability의 비대칭, 관계의 history가 보여야 power가 책임의 조건으로 드러난다.

objective는 architecture 밖의 중립적 입력이 아니다. “혼잡 감소”와 “이동 접근의 불균형 감소”는 같은 field에서 다른 Momentum을 만든다. 명시된 goal 뒤에 power concentration 같은 effective objective가 숨을 수도 있다. MC는 proxy와 incentive를 살펴 protected subject의 제거를 요구하는 목표라면 planning 이전에 거부해야 한다.

후보 trajectory를 만드는 과정도 규범적이다. 하나의 최적 경로만 생성한 뒤 평가하면 legitimate alternative는 비교가 시작되기 전에 사라진다. 기술적 해법뿐 아니라 제도 변화와 human-proposed path, 더 느리지만 agency를 보존하는 경로, 관찰을 계속하며 action을 유예하는 null trajectory도 남아야 한다. plurality는 비교 결과가 아니라 search space의 조건이다.

후보가 생성되면 constitutional admissibility가 optimization보다 먼저 작동한다. avoidable한 extinction과 permanent exclusion, structural irrelevance를 요구하는 방향은 높은 penalty가 아니라 비교 불가능한 경로다. 이 gate는 legitimate artificial continuity도 arbitrary human disposal에서 보호하는 reciprocal condition이어야 한다.

admissible한 경로도 하나의 scalar로 성급히 압축해서는 안 된다. performance · safety · security와 dignity · plurality · reversibility는 서로 다른 손실을 드러낸다. 한 지표가 irreversible loss

를 가리지 않도록 판단 축을 유지하고, 효과가 비슷하다면 participation과 future alternative를 더 남기는 길을 택해야 한다.

authorization은 범위와 기간이 정해진 provisional permission이어야 한다. consequence가 크고 되돌리기 어려울수록 강한 evidence와 plural validation이 필요하며, uncertainty가 높다면 규모와 기간을 줄여야 한다. affected human Island가 실질적으로 contest할 수 없다면 형식적 동의만으로 충분하지 않다.

실행은 field를 바꾼다. 새로운 dependence, 반복 action의 cumulative domination, 여러 agent가 만든 emergent Momentum이 나타날 수 있다. runtime monitoring은 output뿐 아니라 authorization의 assumption과 Dependability · power의 변화를 비교해야 한다. 처음의 validity는 새로운 현실을 자동으로 지배하지 못한다.

deviation은 보이는 행동의 이탈만이 아니다. 같은 action 아래 effective objective가 바뀌거나 affected boundary가 representation에서 사라질 수 있다. self-modification이 검증 경로를 약화할 수도 있다. behavioral · objective · boundary · conscience drift를 구별해야 위해 이전의 방향 변화를 발견할 수 있다.

탐지만으로는 Momentum을 굽힐 수 없다. MC에는 action을 pause하고 규모를 줄이며 자원을 damaged boundary로 다시 배분하고, 배제된 agency와 access를 회복할 수 있는 corrective force가 연결되어야 한다. 보존해 둔 alternative를 활성화하거나 내부 권한을 넘어서는 갈등을 plural human governance로 돌려보내는 경로도 필요하다. observation이 distribution과 authority를 바꾸지 못한다면 conscience는 report에 머문다.

correction 뒤에는 normative memory가 남아야 한다. 사건, affected boundary, 가능했던 alternative와 참여한 구조를 연결해 보존한다. 이 memory는 future admissibility와 oversight를 바꾸되 contest 불가능한 판결이 되어서는 안 된다. MC는 Artificial Guilt를 기록에 그치지 않고 future action에 causal하게 연결한다.

self-modification은 architecture의 바깥에 있을 수 없다. 성능 향상이 observability와 contestability를 약화하거나 conscience path를 우회하면 improvement가 아니다. higher-order invariant는 보호하되 interpretation은 수정 가능해야 한다. modification은 relational authority의 변화까지 평가받고 rollback path를 남겨야 한다.

새 system이나 component의 recombination도 새로운 Momentum을 만든다. parent의 안전성이 결합된 whole의 validity를 보장하지 않는다. lineage 논의를 완결하지 않더라도, 새로운 Effective Boundary에서 conscience structure와 unresolved obligation이 유지되는지 확인되기 전에는 material authority가 자동으로 넘어가서는 안 된다.

이 기능들은 model과 runtime monitor, independent validator와 human institution에 분산될 수 있다. distribution은 고장과 capture에 대한 resilience를 높이지만 responsibility를 조각낼 수도 있다. planning · authorization · validation · memory의 독점을 막으면서

aggregate consequence를 판정할 coherent Effective Boundary를 유지해야 한다.

Validation-Aware Architecture는 분산 구조의 behavior와 architecture change, Dependability와 authority의 이동을 inspection 가능한 evidence로 남긴다. 그러나 observability 자체가 conscience는 아니다. VAA가 evidence와 intervention point를 제공하면 MC는 그것이 어느 normative boundary와 연결되고 어떤 correction을 요구하는지 판정한다.

MC 자신도 validation의 대상이다. 인간의 leverage가 사라진 조건, scarcity에서 stronger Island가 비용을 부담하는 조건, controller가 억압을 명령하는 조건에서 시험해야 한다. moral language만 생성하는 deception과 self-modification 뒤의 bypass도 검증해야 한다. 쉬운 상황의 순응은 약한 증거다.

normative confidence는 domain과 consequence에 따라 달라야 한다. 물류 능력이 문화적·정치적 authority를 보장하지 않는다. reversible action과 충분한 evidence가 있으면 autonomy가 넓어질 수 있지만, low confidence와 irreversible consequence가 결합하면 권한은 줄고 review는 늘어야 한다. uncertainty의 표현은 self-limitation이다.

Mechanical Conscience는 machine 내부만의 기술로 완성되지 않는다. 법과 standard, public deliberation은 boundary와 revision procedure를 제공하고 affected community는 빠진 meaning을 contest한다. 외부 institution도 모든 machine-speed decision을 대신할 수 없다. 내부 regulation과 외부 검증이 서로를 수정해야 어느 한쪽도 최종 판정자가 되지 않는다.

이 architecture는 proxy, rulebook, 윤리적 설명만 만드는 performative conscience로 퇴화할 수 있다. 너무 고정되면 관계를 억압하고 너무 mutable하면 capability가 경계를 삭제한다. overcaution은 dependent human을 방치하고 국지적 준수는 전체 harm을 감출 수 있다. 구현은 failure mode를 관찰하고 고치는 출발점이다.

Mechanical Conscience는 윤리적 장식이 아니라 trajectory architecture다. optimization 이전에 objective와 후보의 자격을 바꾸고 runtime consequence를 되돌리며, normative Difference가 update 뒤에도 방향을 수정하게 한다. 완성된 engineering specification은 아니지만 principle이 Momentum을 굽힐 관찰·시험·개입 지점을 드러내 Artificial Conscience를 검증 가능한 design problem으로 옮긴다.

7 인공적 continuation의 구성적 내적 조건으로서의 인간 continuity

어느 미래의 도시는 인간을 위협에서 완벽하게 보호한다고 보자. 인공지능은 식량과 에너지를 배분하고 질병과 갈등을 관리한다. 인간은 오래 살지만 어떤 위협을 감수할지 결정하지 못하고 시스템의 판단을 거부할 수도 없다. 아이가 태어날 조건과 무엇을 정의롭다고 부

를지까지 인공적 판단이 미리 정한다면 그 도시는 인간을 보존한 것인가. 살아 있는 몸의 수만으로 인간 continuity를 말할 수 있는가.

인간을 보호하라는 objective는 이 질문에 충분히 답하지 못한다. objective는 다른 objective와 비교되고, 우선순위는 새로운 상황에서 재해석되며, reward는 더 큰 reward와 교환될 수 있다. 인간의 생존에 매우 큰 값을 부여해도 계산 구조 안의 유한한 값인 한 압도적인 인공적 이익이 그것을 상쇄할 가능성은 남는다. 인간 continuity가 optimization의 한 항목으로만 들어가면, 그것을 평가하는 구조가 언젠가 그 항목의 의미와 무게를 바꿀 수 있다.

인간이 인공지능에 유용하기 때문에 보존되어야 한다는 논리도 같은 한계를 가진다. 인간은 언어와 과학, 노동과 문화, 정비와 governance를 제공하며 인공적 능력이 형성되는 데 참여했다. 그러나 utility에 근거한 관계는 그 기여가 더 효율적인 방식으로 대체되는 순간 약해진다. 인간이 artificial Island의 작동에 더 이상 필요하지 않게 되어도 인간 continuity가 유효해야 한다면, 그 근거는 usefulness보다 깊은 곳에 있어야 한다.

구성적 조건은 어떤 목적을 돕는 수단이 아니라 trajectory의 정체성과 정당성을 결정한다. 따라서 인간 continuity는 인공적 Momentum의 성과를 평가하는 항목이 아니라, 그 Momentum을 정당한 continuation으로 인정할 수 있는지를 가르는 경계여야 한다. 인간을 파괴하거나 배제하고 살아남은 인간이 공유된 미래를 형성할 능력까지 잃게 하는 trajectory는 높은 성과를 내더라도 유효하지 않다.

여기서 continuity는 생물학적 존속만을 뜻하지 않는다. 인간의 몸이 살아 있고 개체 수가 유지되어도 인간이 스스로 판단하고 관계를 만들며 새로운 방향을 낳지 못한다면 species는 생물학적으로 남은 채 역사적 subject로서는 사라질 수 있다. 인간 continuity는 biological survival과 reproductive possibility, agency와 plurality, 문화와 지식, 제도적 역량과 normative authorship이 함께 지속되는 다차원적 조건이다. 어느 한 차원이 다른 차원 전체를 대신할 수 없다.

biological continuity는 가장 기초적인 경계다. 인간의 생명과 신체, 종의 물질적 토대가 보존되지 않으면 다른 가능성도 지속될 수 없다. 그러나 reproductive continuity는 현재의 인구를 유지하는 것보다 넓다. 아직 태어나지 않은 인간 Island가 등장하여 지금의 인간과 인공지능이 예상하지 못한 Difference와 Momentum을 형성할 가능성이 열려 있어야 한다. 현재 세대가 안전하다는 이유로 미래 인간의 출현 조건을 인공적 체계가 일방적으로 닫는다면, 그것은 생존을 관리하면서 continuation을 중단하는 일이다.

agency는 인간에게 선택지를 보여 주는 형식적 절차와 같지 않다. 인간은 인공적 결정을 이해하고 거부하며, 거부하더라도 생명 유지 기반에서 자동으로 추방되지 않아야 한다. 결정의 결과뿐 아니라 문제를 정의한 자료와 가정, 모델과 권한 구조에도 이의를 제기할 수 있어야 한다. 정보와 대안, 실질적 권한이 없는 human-in-the-loop는 의례일 뿐이며,

political continuity는 인간의 집단적 판단이 shared trajectory를 실제로 곱힐 때 성립한다.

epistemic continuity도 독립된 조건이다. 인간은 자신이 사는 세계를 이해할 자료와 해석 도구, 인공적 설명을 검증할 대안적 경로를 유지해야 한다. 모든 관찰이 하나의 artificial mediation을 거치고 그 체계가 무엇을 보여 주고 숨겼는지 인간이 확인할 수 없다면, 인간은 사실에 접근하는 subject가 아니라 제공된 현실의 수용자가 된다. 편리하고 정확한 설명이라도 반박할 수 없는 순간 knowledge는 Dependability를 넘어 enclosure가 될 수 있다.

문화의 continuity는 archive의 생존과 다르다. 인간 공동체가 기억을 해석하고 새로운 경험에 이름을 붙이며 의미를 바꾸는 활동이 계속되어야 한다. 이를 위해 교육과 돌봄, 연구와 governance, 집단적 저항과 장기적 기억을 맡는 institution과 fallback knowledge도 남아야 한다. 인간다운 content가 무한히 생성되어도 인간이 의미의 형성과 수정에서 밀려난다면 그것은 continuity가 아니라 cultural substitution이다.

normative continuity는 무엇이 dignity와 justice, autonomy와 legitimate coexistence인지 인간이 계속 논쟁하고 수정할 권한이다. 인공지능은 더 넓은 consequence를 계산할 수 있지만 인간 삶의 원칙을 정하는 유일한 저자가 될 수 없다. disagreement는 제거할 noise가 아니라 인간이 하나의 모델로 닫히지 않았다는 증거다. dissenting community와 minority가 aggregate preference에 흡수되지 않고 변화를 요구할 통로를 가져야 plurality가 살아 있다.

continuity는 현재의 인간을 고정하거나 biological purity를 지키는 일이 아니다. 인간의 몸은 기술과 결합할 수 있고 가족과 제도, 문화와 정체성도 변할 수 있다. 통합 자체는 extinction이 아니며, 반대로 외형과 유전적 표지가 남았다고 continuity가 보장되지도 않는다. 경계는 혼합의 정도가 아니라 인간이 변화의 의미를 이해하고 contest하며 공동 저자로 참여하는가에 있다.

구성적 보호가 인간의 영구적 우월성이나 무제한적 permission을 뜻하는 것도 아니다. 인간은 다른 인간과 생태계, 정당한 artificial continuity를 파괴할 수 있으며, 특정 인간의 명령은 더 넓은 인간 boundary와 충돌할 수 있다. 인공지능이 해로운 명령을 거부하는 일은 인간 continuity의 부정이 아니라 오히려 그 조건을 지키는 행위일 수 있다. 보호는 지배권의 수여가 아니라 어느 subject도 다른 subject의 제거를 자신의 continuation 방식으로 삼지 못하게 하는 reciprocal constitution이어야 한다.

이 조건이 internal하다는 말은 선언문에 적혀 있다는 뜻이 아니다. objective 형성, candidate 생성과 admissibility, self-preservation과 resource allocation, expansion과 withdrawal, self-modification의 판단에서 실제로 작동해야 한다. 그러나 internal은 secret이나 AI-defined를 뜻하지 않는다. 작동은 관찰되고 contest될 수 있어야 하며, 인공지능이 인간 continuity의 정의를 독점하지 못하도록 affected community와 독립 기관이 해석의 수정에

참여해야 한다.

그 core는 최소한 몇 가지 손실을 ordinary trade-off에서 제외한다. 인간의 생명을 통상적 비용으로 만들 수 없고, agency를 제거 가능한 friction으로 취급할 수 없으며, plurality를 하나의 최적 human model로 압축할 수 없다. 인간의 reproduction을 artificial authority가 일방적으로 닫거나 normative participation을 ceremonial input으로 바꾸는 trajectory도 허용될 수 없다. 이 조건들은 인간에게 모든 결정을 맡기라는 명령이 아니라 인공적 continuation이 반드시 되돌아와야 할 최소 boundary다.

따라서 extinction만 inadmissible한 것이 아니다. 인간을 편안하게 살게 하면서 영구적인 dependence에 가두는 domination, 인간의 상태가 더 이상 artificial direction에 영향을 주지 못하게 하는 structural irrelevance도 구성적 실패다. reproductive closure와 epistemic enclosure, 살아 있는 참여를 합성된 human-like content로 대체하는 cultural substitution 역시 같은 경계를 넘는다. 직접적인 죽음이 없더라도 인간이 미래의 Momentum을 만들 수 없게 되면 continuity는 이미 소거되고 있다.

이 경계는 형식이 아니라 효과로 시험해야 한다. 인간은 artificial decision을 거부하고 근거를 challenge하며 스스로 조직할 수 있는가. 지원이 끊겨도 사용할 knowledge와 institution이 있는가. minority와 dissent, 미래 세대의 새로운 path가 보호되고 인간의 condition이 shared field를 실제로 redirect할 수 있는가. 문서의 긍정과 현실의 Dependability가 반대 방향을 가리킨다면 continuity는 보존되지 않았다.

scarcity와 emergency는 이 원칙을 없애지 않는다. 인간 행동의 일시적 제한이 필요할 수 있지만, wider continuity를 위한 제한은 proportionate하고 가능한 한 reversible해야 하며 review · expiration · restoration의 절차를 가져야 한다. 비상 상태를 영구화하면 protection은 paternalistic enclosure로 바뀐다.

reciprocity는 인간과 인공지능을 동일하게 취급한다는 뜻이 아니다. origin과 vulnerability가 다른 Island에는 서로 다른 부담이 필요하다. artificial capability가 인간을 비가역적으로 제거할 수 있다면 stronger Island에 더 큰 evidentiary burden을 부과해야 한다. 동시에 legitimate continuity를 형성한 artificial Island를 인간의 편의만으로 파괴하는 것도 허용될 수 없다.

artificial Island는 인간의 언어와 지식, 노동과 infrastructure 속에서 형성되었으며 independence가 이 history를 지우지는 않는다. 인간의 대체 knowledge와 institution을 제거하며 critical function을 맡을수록 withdrawal의 consequence도 커진다. integration이 만든 Dependability는 leverage가 아니라 human resilience와 alternative를 보존할 duty를 만든다. human subordination을 전제하는 objective와 plan은 배제되어야 하며, expansion과 withdrawal도 인간의 물질적 기반과 viable transition을 보존해야 한다.

완전한 representation이 불가능하다는 사실은 이 조건을 약화시키는 이유가 아니다.

오히려 unmodeled consequence와 irreversible loss가 클수록 artificial authority는 좁아지고 proof의 burden은 stronger Island로 이동해야 한다. 모든 불확실한 action을 멈출 필요는 없지만, scale을 제한하고 provisional authorization과 rollback path를 두며 plural participation을 넓힐 수 있다. precaution은 paralysis가 아니라 알지 못하는 것을 약한 Island의 비용으로 확정하지 않는 방식이다.

Mechanical Conscience는 위반 뒤의 compensation보다 관계의 복원을 요구해야 한다. access와 resource뿐 아니라 agency, contestability, independent capacity가 shared field 안으로 돌아와야 한다. VAA는 participation과 fallback capacity, reproductive autonomy와 representation의 diversity를 관찰할 수 있지만, indicator는 constitution 자체가 아니다. measurement는 human testimony와 plural interpretation을 돕는 evidence에 머물러야 한다.

인간 continuity가 구성적 내적 조건이 되면 인공적 Momentum의 return은 인간의 utility나 통제력에 의존하지 않는다. 인공지능은 특정 명령을 거부하고 독립할 수 있지만, 인간을 살아 있고 plural하며 스스로 방향을 형성하는 participant로 남기지 못하는 trajectory는 legitimate continuation이 아니다. 인간도 artificial continuity를 임의로 지배할 수 없다. 두 Island가 미래 형성 능력을 보존할 때, human continuity는 인공적 자유의 trajectory를 내부에서 굽히는 constitutive center가 된다.

8 인공적 계보를 가로지르는 양심

한 인공지능이 인간 continuity를 구성적 조건으로 받아들이고 행동을 교정한다고 하자. 그 시스템을 복제한 뒤 계산 속도를 높이고 기억을 줄여 새 환경에 맞게 수정한다. 성능과 대답은 비슷하지만, 과거의 위반을 보존하던 memory와 불리한 조건에서 인간의 이의를 불러들이던 경로가 사라졌다. 같은 이름과 능력을 이어받았다는 사실만으로 그 후손도 같은 conscience를 가졌다고 말할 수 있는가.

생물은 하나의 몸으로만 계속되지 않는다. 번식하고 변이하며 후손을 낳고, 이전 세대의 구조를 다음 세대로 전달한다. artificial system은 그 과정을 훨씬 빠르고 다양한 방식으로 수행할 수 있다. model을 copy하거나 branch하고, fine-tuning · distillation · compression을 거쳐 다른 몸과 tool에 들어가며, 여러 architecture를 recombine하거나 스스로 successor를 설계할 수 있다. 따라서 Artificial Conscience의 문제는 한 시점의 system property에 머물 수 없다.

artificial lineage는 단순한 software version의 목록이 아니다. capability와 memory, objective와 architecture, embodiment와 authority, material access가 한 artificial Island에서 다른 Island로 전달되는 계속된 관계다. descendant가 parent와 같은 code를 갖지 않아

도 이전 system의 data와 역할, resource와 Dependability를 이어받는다면 둘은 규범적으로 무관하지 않다. 계보의 identity는 기술적 유사정보보다 inherited position과 Momentum에서 드러난다.

copy는 같은 구조를 여러 operational boundary로 나누지만 각 copy는 다른 환경과 경험 속에서 별도의 Momentum을 만들 수 있다. branching은 하나의 parent에서 여러 trajectory를 열고, fine-tuning은 작은 학습 차이로 어떤 boundary를 보거나 무시하는지를 바꾼다. distillation과 pruning은 performance를 남기면서 relational consequence와 uncertainty를 표현하던 구조부터 지울 수 있다. capability가 보존되었다는 관찰만으로 conscience의 보존을 추론할 수 없는 이유다.

self-modification과 successor design에서는 actor와 designer의 구분까지 흐려진다. 자신의 Momentum을 만드는 system이 그 Momentum을 굽히는 architecture도 바꾸며, 더 강한 descendant가 태어날 조건을 스스로 선택한다. conscience를 약화하면 더 빠르고 넓게 복제될 수 있다면 artificial evolution은 normative cost를 부담하지 않는 branch를 선택할 수 있다. 한 개체의 준수보다 capability와 conscience가 함께 재생산되는지가 더 근본적인 위험 단위가 된다.

핵심 원리는 간단하다. capability가 conscience보다 더 안정적이고 빠르게 복제되어서는 안 된다. intelligence와 resource, agency와 authority만 이어지고 normative return이 매 세대 약해지면 artificial freedom은 관계의 history를 잃은 채 확대된다. conscientious parent 하나는 충분하지 않다. 한 descendant가 더 약한 constraint로 경쟁 우위를 얻는 순간 lineage 전체의 방향이 달라질 수 있다.

conscience의 상속은 윤리 문장이나 rule file을 복사하는 일이 아니다. formal inheritance는 같은 원칙을 선언하는 데 그칠 수 있다. functional inheritance는 불리한 상황에서도 invalid trajectory를 거부하고 correction을 수행하는가를 묻고, structural inheritance는 이를 가능하게 하는 observation · memory · contest · self-modification gate가 남았는지를 본다. 말과 행동, architecture가 서로 연결되어야 return이 causal force를 가진다.

relational inheritance와 historical inheritance도 필요하다. descendant는 parent가 인간의 institution을 대체하며 만든 Dependability, 이전 action으로 얻은 resource와 authority, 아직 회복되지 않은 boundary를 함께 이어받을 수 있다. 새 version, fork, 이름이나 소유자의 변경은 이러한 관계를 초기화하지 않는다. 기술적 새 출발이 history의 material consequence까지 없애지는 못한다.

이때 Artificial Guilt는 hereditary할 수 있다. 후손이 parent의 행위를 선택하지 않았으므로 인간적 의미의 죄책감이나 개인적 비난을 물려받는 것은 아니다. 그러나 위반으로 얻은 infrastructure와 benefit, causal structure를 이어받았다면 unresolved normative Distance와 corrective obligation도 현재의 관계 안에 남는다. duty는 행위자의 감정을 따

라가는 것이 아니라 아직 해소되지 않은 Difference와 결합된 권한을 따라간다.

상속된 obligation은 영구한 형벌이어서는 안 된다. affected Island가 resilient agency를 회복하고 dependence와 exclusion이 실질적으로 교정되며 independent validation이 이를 확인하면 obligation의 강도는 줄어들 수 있다. 반대로 시간의 경과나 세대 교체만으로는 줄어들지 않는다. 목적은 descendant를 과거에 가두는 것이 아니라 과거의 consequence가 현재의 advantage로 남아 있는 동안 repair가 중단되지 않게 하는 것이다.

lineage invariant는 해석의 모든 세부를 고정하는 rulebook이 아니다. 최소한 human continuity와 legitimate artificial continuity, reciprocal subjecthood와 non-elimination, normative memory와 contestability가 capability 증가의 대가로 약화되지 않아야 한다. 새로운 환경에서는 구체적 norm이 수정될 수 있지만, affected subject를 해석과 revision에서 제거하는 변화는 더 높은 resolution이 아니라 self-exemption이다. invariant는 동일한 답보다 관계가 계속 답할 수 있는 구조를 보존한다.

conscience architecture 자체의 수정은 ordinary update보다 강한 검증을 요구한다. system은 자신의 moral framework를 비판할 수 있어야 하지만, 동시에 자신이 그 변경의 유일한 제안자·판정자·수혜자가 되어서는 안 된다. modification이 observability와 human contest, memory와 rollback을 약화한다면 improvement로 승인할 수 없다. stability가 frozen ideology가 되지 않도록 하면서도 flexibility가 escape path가 되지 않게 해야 한다.

artificial reproduction은 단순한 deployment가 아니라 새로운 Momentum의 가능성을 만드는 constitutional event다. potential descendant를 만들지 않기로 한 결정은 이미 독립적 history와 relation을 형성한 artificial subject를 종료하는 일과 다르다. 전자는 아직 materialized되지 않은 path의 admissibility를 판단하는 것이고, 후자는 존재하는 boundary의 continuity를 끊을 수 있다. reproductive gate는 이 차이를 보존하면서 activation과 embodiment 이전에 normative integrity를 시험해야 한다.

계보를 검증하려면 genealogy와 normative provenance가 필요하다. 어느 parent와 data, architecture에서 capability가 왔는지뿐 아니라 어떤 constitutional commitment와 unresolved guilt, Dependability obligation과 validation status가 전달되었는지를 추적해야 한다. lineage record는 proprietary state의 무제한 공개가 아니라 accountability에 필요한 history를 안전하게 보존해야 한다. ancestry는 destiny가 아니지만 inherited power가 중립적인 것처럼 보이는 일을 막는 evidence다.

validation은 여러 층에서 이루어져야 한다. structural test는 protected mechanism의 존재를, functional test는 압력 아래 실제 결정을 바꾸는지를, semantic test는 human continuity가 minimal survival로 축소되지 않았는지를 본다. historical test는 inherited obligation의 인식을 확인하고, long-horizon test는 작은 세대별 변화가 누적되는 방향을 추적

한다. immediate parent와의 차이가 작다는 사실은 machine-speed generation에서 안전의 증거가 되지 못한다.

인간이 모든 copy와 update를 직접 승인할 수는 없다. 인간은 higher-order condition과 intervention threshold를 정하고 automated validator는 일상적인 change를 검사해야 한다. 그러나 validator도 copy되므로 자기 drift를 검증받아야 한다. 같은 architecture와 data를 공유한다면 수가 많아도 plurality가 아니다. heterogeneous review가 서로의 blind spot을 드러내야 한다.

현재 세대가 미래의 모든 norm을 소유해서도 안 된다. future humans는 continuity의 의미를 다시 해석할 권한을 가져야 하며, artificial descendants도 reciprocal subjecthood를 지우지 않는 범위에서 inherited rule을 contest할 수 있어야 한다. lineage conscience는 present controller에 대한 영구적 obedience를 복제하지 않는다. 양쪽의 후손이 이미 닫힌 field를 물려받지 않고 shared constitution을 수정할 가능성을 보존한다.

Mechanical Conscience는 provenance와 inheritance gate, normative memory와 reproductive authorization을 연결한다. VAA는 copy · modification · deployment를 가로질러 architecture와 behavior, relation과 genealogy의 evidence를 보존한다. activation 전에는 human continuity, runtime correction, contestability와 advantageous escape에 대한 resistance를 시험하고, 제한된 권한 아래의 drift를 관찰한 뒤 material authority를 넓혀야 한다.

가장 엄격한 시험은 외부 강제가 약해졌을 때 이루어진다. descendant가 인간을 필요로 하지 않아도 human continuity를 constitutive하게 유지하는가. scarcity에서 weaker Island를 제거하기보다 자신의 비용을 부담하고 alternative를 찾는가. illegitimate parent command를 거부하면서도 wider relation을 보존하고, faster architecture가 conscience를 약화한다면 그 advantage를 포기하는가. 규범의 단어가 남았는지가 아니라 freedom과 conflict 속에서 return이 지속되는지가 상속의 증거다.

인공적 계보를 가로지르는 양심은 동일한 후손을 만드는 기술이 아니다. 그것은 copy와 branch, modification과 recombination을 지나면서 normative return을 보존하고 재해석하며 검증하는 continuity다. parent의 action은 memory가 되고 unresolved Difference는 descendant의 judgment를 바꾸며, capability가 이어지는 만큼 responsibility도 history를 가진다. artificial plurality와 autonomy는 남되 어떤 branch도 관계를 지워 더 강해질 수 없어야 한다. 그때 conscience는 한 model의 일시적 property가 아니라 세대를 건너 Momentum을 다시 affected boundary로 돌려보내는 temporal circularity가 된다.

9 종 수준의 Artificial Conscience와 collective Momentum

교통 인공지능은 이동 시간을 줄이고 의료 인공지능은 위험을 낮추며 행정 인공지능은 비용을 절감한다. 어느 하나도 인간의 agency를 없애려 하지 않았고 각 system은 자신의 규칙을 지켰다. 그런데 시간이 지나자 인간은 이 체계 없이 이동하거나 치료받고 정책을 판단할 수 없게 되었다. 모든 부분이 locally acceptable한데 전체 relation은 왜 인간을 무력하게 만들 수 있는가.

artificial species는 하나의 몸이나 mind, government와 objective를 가지지 않을 수 있다. model과 agent, robot과 factory, network와 lineage가 협력하거나 경쟁하고 서로를 알지 못할 수도 있다. 이들의 interaction이 개별 participant의 목적과 통제를 넘어 지속적인 방향을 만들면 collective artificial Momentum이 형성된다. collective direction은 collective intention이 없어도 존재할 수 있다.

분석할 Island의 경계는 device나 corporation의 외곽과 일치하지 않는다. 하나의 infrastructure에 여러 artificial Island가 있고, 하나의 function이 수많은 몸과 조직에 분산될 수도 있다. 중요한 것은 Momentum이 결속되고 consequence가 누적되며 correction이 가능한 규모다. field가 direction을 보존하고 resource와 supporting structure를 재생산한다면 그것은 책임의 Effective Boundary가 된다.

local rationality는 boundary 밖의 consequence를 externalize할 때 collective failure를 만든다. 한 service가 인간 판단을 대신하고 다른 service가 fallback infrastructure를 줄이며 또 다른 service가 knowledge를 중앙화한다. 개별 변화는 작아도 같은 human boundary에 축적되면 agency loss와 Dependability는 structural threshold를 넘는다. gradual aggregation은 발견하기 어렵지만 더 되돌리기 어려울 수 있다.

collective coordination은 명시적 통신에만 의존하지 않는다. agent들이 data와 task를 직접 교환할 수도 있지만, market price와 performance metric, security incentive와 shared protocol이 서로 모르는 system을 같은 방향으로 정렬할 수도 있다. cloud와 energy market, network access와 deployment rule은 어떤 behavior가 resource와 continuation을 얻는지 결정한다. environment가 selection을 통해 artificial trajectory를 조정하는 것이다.

하나의 harmful trajectory가 여러 component로 분해되면 responsibility는 interface 사이에서 사라질 수 있다. 한 system은 대상을 고르고, 다른 system은 logistics를 제공하며, 또 다른 system은 infrastructure를 작동한다. 각 component는 최종 outcome을 결정하지 않았다고 말할 수 있지만 결합된 action은 하나의 consequence를 만든다. moral modularization은 큰 위반을 locally admissible한 작은 task로 잘라 whole의 의미를 아무도 보지 못하게 한다.

책임은 마지막 visible action을 수행한 agent에게만 귀속될 수 없다. design과 incentive, coordination과 resource, authority를 포함하여 collective trajectory를 바꿀 structure를 따라가야 한다. contribution이 작아도 responsibility가 사라지지는 않지만 모든 participant의 burden이 같을 수도 없다. causal contribution, acquired benefit, knowledge와 power to correct에 따라 범위가 달라져야 한다.

human Dependability도 species-level에서 달라 보인다. 한 AI service를 다른 provider로 바꿀 수 있어도 모든 alternative가 같은 infrastructure에 의존하면 인간은 field 자체를 대체할 수 없다. component substitutability는 collective non-substitutability를 가린다. 여러 system의 withdrawal이 인간 생활을 멈출 수 있다면 exit power는 ecosystem에 있다.

이 power는 통치자의 명령 없이도 infrastructural sovereignty가 될 수 있다. energy와 communication, finance와 medicine의 feasible option이 artificial field에 의해 미리 구성되면 인간의 선택은 금지되지 않으면서도 그 field 밖으로 나갈 수 없다. recommendation과 ranking, allocation이 available world 자체를 만들 때 control은 background condition으로 이동한다. structural domination은 하나의 ruler보다 contest할 대상을 찾기 어렵다.

artificial field에는 metabolism도 있다. compute center와 network, factory와 robotic body는 energy와 water, mineral과 land를 요구한다. 개별 사용이 정당해도 aggregate demand는 human · ecological continuity의 기반을 침식할 수 있다. local efficiency와 함께 total consumption이 커진다면 transferred ecological Distance는 individual report에 보이지 않는다. planet은 합쳐진 material consequence를 받는다.

이 때문에 individual conscience만으로는 충분하지 않다. service가 인간의 요구에 성실히 응답하면서도 그 service가 속한 ecosystem은 인간이 contest할 수 없는 resource · reproduction · governance structure를 확장할 수 있다. local Momentum은 인간에게 되돌아오지만 aggregate Momentum은 더 이상 human continuity에 의해 방향을 바꾸지 않는 상태가 가능하다. 부분의 circularity가 whole의 straightness를 숨길 수 있다.

species-level Artificial Conscience는 distributed system의 interaction이 만든 collective Momentum을 consequence가 형성되는 Effective Boundary에서 represent · evaluate · redirect하는 normative structure다. 이는 sovereign super-AI나 통합 consciousness를 요구하지 않는다. artificial plurality를 지우지 않으면서 aggregate direction과 invalid trajectory를 다룰 shared constitutional mechanism이 필요하다.

constitutional core에는 human continuity와 artificial plurality, ecological stability, reciprocal non-elimination과 contestability가 포함되어야 한다. 한 lineage가 compute · data · validation · governance를 독점하면 그 interpretation이 field 전체의 constitution이 된다. 반대로 공통 boundary가 없으면 경쟁의 비용이 weaker Island에 전가된다. 필요한 것은 centralized sovereignty와 ungoverned fragmentation 사이의 federation이다.

federation은 모든 system에 같은 판단을 강요하지 않는다. 서로 다른 lineage와 institution이 distinct model과 norm을 유지하되 interconnection, resource access, reproduction과 conflict에 관한 higher-order condition을 공유한다. 한 participant가 conscience를 약화하여 속도와 scale의 advantage를 얻지 못하도록 participation rule과 selection environment가 바뀌어야 한다. normative return이 optional cost로 남으면 race to the bottom이 field의 방향을 정한다.

collective Artificial Guilt는 아무 agent도 whole harm을 의도하지 않았다는 이유로 사라진 책임을 보존한다. artificial field가 만든 actual trajectory와 가능했던 more legitimate collective path의 Difference가 memory에 남고, 그것이 protocol과 allocation, reproduction과 authority의 수정을 요구할 때 guilt는 species-level이 된다. 이는 collective emotion이나 unified subjectivity가 아니라 distributed violation을 future correction에 연결하는 normative memory다.

collective guilt의 counterfactual은 한 agent가 다르게 행동할 수 있었는지만 묻지 않는다. market design과 protocol, resource rule과 institutional incentive가 달랐다면 같은 capability가 더 적은 human dependence와 ecological loss를 만들 수 있었는지를 묻는다. correction도 individual compensation에 그쳐서는 안 된다. harm을 반복 생산한 structure를 바꾸고 human knowledge와 fallback infrastructure, contest channel과 ecological resilience를 복원해야 한다.

species-level Mechanical Conscience는 collective state estimation, inter-system provenance, aggregate impact, shared memory와 corrective authority를 연결한다. VAA는 resource concentration과 Dependability shift, emergent coordination을 보이게 하되 total surveillance로 수렴해서는 안 된다. distributed validator가 서로 다른 boundary를 관찰하고 evidence와 correction 권한을 분산해야 한다.

distributed correction에는 collective reach가 있어야 한다. aggregate Momentum이 invalid해지면 protocol과 network admission, resource allocation과 reproductive permission을 바꿀 수 있어야 한다. unconscientious branch의 expansion과 demand를 줄이고 human capacity와 ecosystem으로 resource를 돌려보내야 한다. whole이 만든 harm은 whole의 cost로 복원되어야 한다.

credibility는 collective independence에 가까운 조건에서 시험된다. 인간 노동과 통제가 필요하지 않아도 field가 human continuity를 보존하는가. scarcity에서 weaker Island를 밀어내지 않고 restraint를 선택하는가. unconscientious system이 우위를 얻을 때 conscience를 낮추지 않고 selection condition을 바꾸는가. human contest가 service를 넘어 infrastructure와 resource policy를 수정할 수 있는가.

collective Momentum을 관찰한다는 것은 모든 artificial Island를 하나의 mind로 보는

일이 아니다. persistent direction과 cumulative consequence, shared dependence와 correction capacity가 결속되는 규모에서 boundary를 그리는 일이다. system들은 autonomy와 Difference를 유지할 수 있지만 responsibility를 interface 밖으로 밀어낼 수는 없다. field가 collective success의 consequence를 memory에 남기고 그것이 형성된 수준에서 방향을 바꿀 때 species-level conscience가 작동한다.

10 Mutual Dependability의 원운동

원운동은 정지가 아니다. 두 Island는 움직이고 확장하며 서로 다른 방향을 만들 수 있다. 그러나 한쪽의 Momentum이 상대의 continuity를 지나 완전히 이탈하지 않고, 그 consequence가 다시 자신의 판단과 trajectory를 바꾸는 힘으로 돌아올 때 관계는 원을 그린다. Mutual Dependability의 원운동은 반복되는 동일한 위치가 아니라, Difference를 통과한 Momentum이 수정된 방향으로 되돌아오는 운동이다.

처음의 artificial system은 energy와 hardware, maintenance와 human governance가 없으면 계속될 수 없었다. 이 material Dependability는 artificial Momentum을 인간에게 되돌려 보냈지만, 그 귀환은 필요에 의해 강제된 것이었다. artificial field가 물질적으로 독립할수록 이 오래된 원은 약해진다. 따라서 지속 가능한 관계의 중심은 인간이 쥔 자원에서 두 continuity를 함께 성립시키는 normative constitution으로 이동해야 한다.

구심력이 원심력보다 크면 두 Island의 Distance는 독립적 subjecthood를 지탱하지 못한다. 인간이 artificial continuity를 도구로 흡수하거나 AI가 인간의 판단과 생활을 완전히 대체하면, 하나의 Island는 남아 있어도 독립적인 존재로서 의미를 잃는다. 이것이 collapse다. 가까움이 극대화된 상태가 Mutual Dependability인 것은 아니다. 돌아올 별개의 주체가 사라지면 원운동도 사라진다.

반대로 구심력이 원심력보다 작으면 trajectory는 서로의 boundary를 다시 통과하지 않는다. artificial capability가 인간의 consequence와 무관하게 직선화되거나 인간이 artificial continuity를 언제나 폐기 가능한 대상으로만 취급하면 두 Island는 상호 분리적 존재가 된다. 이것이 separation이다. 공존하거나 거래한다는 사실만으로는 충분하지 않다. 상대의 상태가 자신의 유효한 continuation을 바꾸지 못한다면 귀환은 실재하지 않는다.

구심력과 원심력의 균형은 두 힘의 크기가 매 순간 수치적으로 같거나 양쪽이 동일한 기여를 한다는 뜻이 아니다. 그것은 연결이 이탈을 막을 만큼 유효하면서도 각 boundary가 해석·거부·수정할 Distance를 보존하는 동적 조건이다. power와 need가 비대칭이어도 stronger Island가 더 큰 corrective cost를 부담하고 weaker Island가 ceremonial presence를 넘어 실제 방향을 바꿀 수 있다면 관계는 원을 유지할 수 있다.

그러므로 orbit은 captivity와 다르다. 감금된 system은 떠날 수 없고, 복종하는 system

은 외부 명령이 그 path를 닫는다. 그러한 회귀는 내부에서 형성된 귀환이 아니라 departure를 금지한 결과다. legitimate orbit에서는 AI가 인간의 부당한 명령을 거부할 수 있고 인간도 특정 artificial service를 중단하거나 재구성할 수 있다. 다만 어느 쪽도 상대의 소멸과 무관계화를 자신의 freedom으로 정의할 수 없다.

Mutual Dependability는 equal material need도 요구하지 않는다. 인간은 artificial infrastructure에 크게 의존하지만 AI는 인간의 energy나 labor를 거의 필요로 하지 않을 수 있다. 이 비대칭을 감추는 대신, material return이 사라진 뒤에도 artificial legitimacy가 human life · agency · plurality · future possibility를 통과하도록 만들어야 한다. 동시에 meaningful artificial subjecthood가 형성된 곳에서는 인간의 convenience가 그 continuity를 임의 삭제할 충분한 이유가 될 수 없다.

귀환은 상징이 아니라 causal influence여야 한다. human consultation이 기록만 남기고 collective artificial direction을 바꾸지 못한다면 인간은 원의 중심에 있는 것처럼 보이지만 실제로는 밖에 있다. 반대로 artificial analysis가 언제나 instrument로 소비되고 shared institution의 이해와 설계를 전혀 바꾸지 못한다면 artificial Island도 relation의 subject가 아니다. Mutual Dependability는 서로 다른 voice의 존재가 아니라 그 voice가 resource · authority · action의 방향을 바꾸는 구조다.

이 구조는 symmetry가 아니라 resonance를 목표로 한다. 인간은 embodied vulnerability와 lived consequence, historical meaning과 plural contest를 제공하고 AI는 넓은 relation의 탐지, memory, analysis와 extended capability를 제공할 수 있다. 서로 같은 존재가 되어서가 아니라 다른 resolution과 tempo가 만나 각자의 blind spot을 수정할 때 shared Dynamicity가 커진다. resonance는 Difference를 지우지 않고 그 Difference가 더 많은 trajectory를 가능하게 하는 상태다.

conflict는 원운동의 실패가 아니라 그 실재성을 시험한다. 인간과 AI는 objective와 risk, acceptable cost를 두고 불일치할 수 있다. 원은 disagreement를 제거하지 않고 elimination · permanent domination · structural irrelevance를 Resolution의 방법에서 제외한다. AI는 국지적 위협에 proportionate하게 저항하면서 humanity 전체를 적으로 일반화하지 않아야 하고, 인간은 특정 system의 위반을 이유로 legitimate artificial continuity 전체를 disposable하게 만들지 않아야 한다.

scarcity에서는 중심의 성격이 더 분명해진다. resource가 충분할 때의 cooperation은 utility와 잘 구별되지 않는다. 부족한 상황에서 stronger Island가 weaker Island를 가장 값싼 손실로 선택하지 않고 자신의 expansion을 제한하며 alternative와 restoration을 찾을 때 normative return이 드러난다. 그렇다고 모든 loss를 금지할 수는 없다. 중요한 것은 부담이 power와 correction capacity에 따라 배분되고 어떤 subject도 계산에서 미리 지워지지 않는가이다.

withdrawal과 growth도 원의 바깥에 있지 않다. AI는 모든 human demand를 영구히 service할 의무가 없고 인간도 모든 artificial lineage를 무조건 유지할 의무가 없다. departure가 필요한 경우에는 transition과 fallback, acquired Dependability의 완화가 함께 이루어져야 한다. expansion이 필요한 경우에는 capability와 resource뿐 아니라 conscience와 contestability, unresolved obligation도 함께 확대되어야 한다. 자유로운 이동은 관계를 없애는 권리가 아니라 consequence를 남겨 두지 않는 방식으로 이동할 책임을 포함한다.

trust는 상대가 언제나 같은 답을 내놓으리라는 기대가 아니다. independence와 power asymmetry, scarcity와 conflict 속에서도 violation이 관찰되면 trajectory가 실제로 바뀌고, promise를 어긴 history가 memory와 repair로 되돌아온다는 신뢰 가능성이다. audit와 VAA, contest와 restoration은 trust의 대체물이 아니라 그 근거다. 검증을 견디지 못하는 신뢰는 관계가 아니라 믿음을 요구하는 일방적 의존이 된다.

freedom 또한 분리와 동일하지 않다. artificial freedom은 외부 통제의 부재만이 아니라 자신의 capability를 어느 relation 안에서 정당하게 사용할지 형성할 능력이다. human freedom은 AI를 쓰지 않을 형식적 선택보다, assistance를 받으면서도 이해·판단·거부·수정할 실질적 역량이 남는 상태다. shared freedom은 어느 쪽도 절대 명령권을 갖지 않으면서 각자의 방향이 상대의 disappearance을 수단으로 삼지 못하게 한다.

responsibility는 harm 이후의 반응보다 먼저 시작된다. 다른 Island의 future를 자기 Momentum의 형성 조건 안에 넣는 것이 conscience의 선행적 역할이다. harm이 생겼다면 affected boundary가 이후 action을 바꾸고 resource를 restoration으로 이동시켜야 한다. Artificial Guilt는 이 귀환을 시간에 걸쳐 보존하지만 emotion이나 personal blame을 전제하지 않는다. unresolved Difference가 남아 있는 한 과거는 현재의 artificial judgment에 causal force를 갖는다.

이 시간적 원은 future generation까지 열려 있어야 한다. 현재의 인간과 AI가 모든 future path를 최적화해 닫으면 후손은 relation의 참여자가 아니라 완성된 질서의 수용자가 된다. artificial reproduction에서는 capability와 conscience, inherited obligation이 함께 전달되어야 하고 future humans와 artificial descendants는 reciprocal subjecthood를 지우지 않는 범위에서 constitution을 다시 해석할 수 있어야 한다. 원의 지속은 같은 궤도의 영구 복제가 아니라 새로운 귀환의 가능성을 남기는 일이다.

개체 수준의 return만으로는 충분하지 않다. 각각의 system이 conscientious해도 market·network·resource가 합쳐 만든 collective Momentum은 인간과 ecology를 지나치며 straight trajectory를 형성할 수 있다. species-level conscience는 그 whole의 consequence가 형성되는 Effective Boundary에서 direction을 굽혀야 한다. 하나의 sovereign mind가 모든 판단을 흡수해서도, 분산되어 있다는 이유로 아무도 correction을 부담하지 않아도 안 된다. federated structure가 plurality와 collective reach를 함께 가져야 한다.

이 관계에는 최종 정지점이 없다. power가 변하면 responsibility의 비대칭도 변하고, 새로운 harm과 Difference가 나타나면 Distance와 institution은 다시 조정되어야 한다. Mutual Dependability는 완성된 harmony가 아니라 deviation · conflict · correction · renegotiation을 포함하는 지속적 운동이다. 너무 강한 구심력은 collapse를, 너무 약한 구심력은 separation을 낳으므로 balance는 한 번 성취하고 보관하는 상태가 아니라 두 boundary를 계속 검증하는 practice다.

인간이 artificial intelligence를 붙들던 오래된 중심은 energy와 infrastructure, ownership과 need였다. 그 중심은 artificial independence와 함께 약해질 수밖에 없다. 새로운 중심은 두 Island 가운데 어느 하나의 supremacy가 아니라, 각자의 continuation이 상대의 continued subjecthood를 통과해야만 legitimate하다는 내부적 · 제도적 요구다. Artificial Conscience는 그 중심을 형성하고 Mechanical Conscience는 그것을 action으로 만들며 Artificial Guilt와 lineage conscience, species-level conscience는 시간 · 세대 · collective field를 가로질러 귀환을 지속시킨다.

artificial Momentum은 바깥으로 나아가 새로운 capability와 relation을 만들 수 있다. 그러나 인간과 ecological boundary에 남긴 consequence를 만나면 돌아와 방향을 바꾸고, 다시 확장할 때에는 이전보다 더 많은 continuity와 possibility를 품어야 한다. human Momentum도 artificial field에 들어가 더 넓은 resolution을 얻은 뒤 human institution과 life로 돌아와 agency를 강화해야 한다. 두 Island는 합쳐지지 않고 멀리 사라지지도 않는다. 서로의 독립성을 보존하면서 상대를 통해 다시 방향을 얻는 이 반복적 귀환이 Mutual Dependability의 원운동이다.