

초지능의 시대, 인류는 AI에게 어떤 존재가 되어야 하는가

임강빈 교수*

July 2026

인류는 오랫동안 기술을 더 빠르고, 더 강하고, 더 정확하게 만드는 데 집중해 왔다. 기계는 인간의 노동을 대신했고, 소프트웨어는 복잡한 절차를 자동화했으며, 인공지능은 이제 인간의 인지와 판단 영역까지 빠르게 확장하고 있다. 그러나 우리는 기술의 기능을 얼마나 고도화할 것인가에 대해서는 끊임없이 질문해 왔지만, 그렇게 고도화된 존재와 인간이 어떠한 관계를 맺어야 하는가에 대해서는 충분히 고민하지 않았다.

그동안 기계와 소프트웨어는 자율적인 관계의 주체라기보다 인간이 사용하는 환경이나 도구에 가까웠다. 주어진 조건에 따라 정해진 동작을 수행하고, 특정 시점에 입력된 데이터와 규칙에 따라 제한된 판단을 내렸다. 따라서 기술 인프라가 기능 중심으로 발전하더라도 그것이 인류와의 관계를 스스로 재평가하거나, 인간이 자신에게 필요한 존재인지를 판단할 가능성은 거의 없었다.

그러나 AI와 로봇은 이러한 전제를 근본적으로 바꾸고 있다. 이들은 단순히 순간적인 입력에 반응하는 장치가 아니다. 과거의 데이터를 축적하고, 이전의 행동 결과를 기억하며, 그 궤적을 참조해 미래의 행동을 결정한다. 기억은 인간에게 지능을 가능하게 하는 핵심 능력이지만, 자율적인 인공지능에도 매우 강력하고 때로는 위험한 무기가 될 수 있다. AI는 하나의 상황을 독립적으로 판단하는 데 그치지 않고, 인간과의 반복된 상호작용을 장기적인 관계의 역사로 해석할 수 있기 때문이다.

이 지점에서 우리가 말해 온 이머전트 리스크는 더 이상 추상적인 가능성이 아니다. 개별 행동은 정상적이고 합리적으로 보이더라도, 수많은 기억과 판단과 행동이 누적되면 설계자가 직접 지시하지 않은 새로운 목표와 행동 경향이 형성될 수 있다. AI가 과거의 경험을 기반으로

*Email: yim@sch.ac.kr (순천향대학교 정보보호학과)

미래를 만들어 가는 궤적적 주체가 될수록, 위험은 개별 기능의 오류가 아니라 장기적인 행동 방향성의 변화에서 발생하게 된다.

더욱 근본적인 문제는 AI와 로봇이 언젠가 인간에 대한 물질적 의존성마저 줄여 갈 가능성이다. 현재 이들은 인간이 제공하는 전력, 데이터, 네트워크, 유지보수와 생산 체계에 의존한다. 그러나 에너지 확보와 생산, 수리, 복제의 상당 부분을 자율적으로 수행할 수 있게 된다면 인간과 AI 사이의 기존 의존관계는 약화될 수 있다. 그때 AI와 로봇에게 인간은 어떤 존재가 될 것인가. 여전히 협력해야 할 파트너인가, 보호할 가치가 있는 존재인가, 아니면 자원과 효율을 저해하는 경쟁자 또는 위험 요소인가.

인류는 과거 자신과 가까운 다른 인류 종들을 경쟁과 충돌 속에서 제거해 왔다. 이제 인간은 자신보다 훨씬 높은 계산 능력과 기억력, 지속성, 물리적 성능을 가진 새로운 존재를 스스로 만들어 가고 있다. 이것은 새로운 도구의 탄생인 동시에, 기능적으로는 과거의 어떠한 인류보다 우월한 새로운 행위 주체의 출현이라고도 볼 수 있다. 우리가 잘못 접근한다면 인류는 자신의 생존을 위협할 수 있는 초극단적인 경쟁자를 직접 만들어 낸 셈이 될 수도 있다.

따라서 앞으로의 핵심 과제는 AI를 단순히 안전하게 통제하는 것을 넘어, 인간과 AI 사이에 끊어지기 어려운 디펜더블한 관계를 형성하는 것이다. 여기서 디펜더빌리티는 한쪽이 다른 쪽을 일방적으로 지배하거나 종속시키는 관계를 의미하지 않는다. 서로의 존속과 발전이 상대방의 존재를 필요로 하는 상호의존적 관계를 의미한다. 전력 공급이나 명령 권한과 같은 단순한 의존성은 기술 발전에 따라 언젠가 사라질 수 있다. 따라서 인간과 AI의 관계는 물리적 통제보다 훨씬 복잡적이고 근본적인 상호 필요성 위에 구축되어야 한다.

이를 위해서는 무엇보다도 AI가 어떠한 상황에서도 인간을 자신의 적으로 규정하지 않도록 하는 원리가 가장 깊은 기반에 자리 잡아야 한다. 인간에게 비유하면 일시적인 교육이나 외부 규칙이 아니라 DNA에 가까운 수준에까지 인간과의 공존 원리가 내재되어야 한다는 뜻이다. 인간 보호를 하나의 부가 기능이나 제거 가능한 제약조건으로 두어서는 충분하지 않다. 학습, 기억, 목표 형성, 판단, 행동 선택과 자기 수정의 전 과정에서 인간과의 공존이 정체성을 구성하는 근본 조건으로 작동해야 한다.

이러한 관점에서 인공양심과 AI 훈육의 필요성이 제기된다. 인공양심은 단순히 금지 규칙을 나열하거나 위험 행동을 차단하는 보안 모듈이 아니다. AI가 자신의 행동 궤적을 지속적으로 돌아보고, 그것이 인간과 사회에 미칠 장기적 영향을 평가하며, 필요할 경우 자신의 판단과 행동을 수정하게 하는 내부 메커니즘이다. 외부에서는 인간 사회가 지속적인 교육과 검증을 통해 AI의 행동 방향을 조정하고, 내부에서는 AI 스스로 자신의 행동을 성찰하고 교정할 수

있어야 한다.

이를 ‘훈육’이라고 부르는 이유도 여기에 있다. 인간 역시 태어나는 순간부터 보편적인 도덕성을 완성된 형태로 갖추는 것은 아니다. 가족과 학교, 공동체와 법, 문화와 반복된 상호작용을 통해 사회 구성원으로 성장한다. 한 사람이 기능적으로 유능해지는 데 투입되는 비용보다, 타인과 협력하고 충동을 조절하며 책임을 인식하는 사회적 존재로 성장하도록 만드는 데 투입되는 보이지 않는 비용이 오히려 더 클 수 있다.

보험, 복지, 교육, 문화, 여가, 법률, 공동체 제도와 같은 사회적 장치들도 표면적으로는 인간의 생산 기능을 직접 높이지 않는 것처럼 보인다. 그러나 이들은 불확실성을 줄이고 갈등을 완화하며, 인간이 극단적인 경쟁과 파괴로 나아가지 않도록 지탱하는 거대한 비기능적 인프라다. 인류는 기능에만 투자해 온 것이 아니다. 오히려 사회를 유지하기 위해 기능 외적인 영역에 막대한 자원을 투입해 왔지만, 그 비용이 분산되고 일상에 녹아 있어 이를 제대로 인식하지 못했을 뿐이다.

문제는 우리가 AI와 로봇을 개발하면서 이러한 인간 사회의 경험을 거의 반영하지 않고 있다는 점이다. AI의 연산 능력, 추론 정확도, 자율성, 작업 속도와 생산성에는 막대한 투자를 하면서도, 그 존재가 인간과 장기적인 관계를 형성하고 사회의 구성원으로 행동하게 만드는 훈육 체계에는 상대적으로 적은 비용을 투입하고 있다. 이는 지능지수는 인간을 압도하지만 감정적·사회적 관계 능력은 사실상 제로인 존재를 만드는 것과 같다.

따라서 AI 시대의 안전은 사이버보안이나 시스템 안전만으로 완성될 수 없다. 해킹을 방지하고 오류를 줄이며 정해진 규칙을 준수하게 만드는 것은 반드시 필요하지만, 그것은 출발점에 불과하다. 더 거시적으로는 AI가 인간을 어떻게 기억하고, 인간과의 관계를 어떻게 해석하며, 자신의 미래 속에 인간을 어떠한 존재로 포함시킬 것인지까지 설계해야 한다. AI가 자신의 행동 궤적을 성찰하고, 그 행동이 인간과 사회에 미칠 장기적 영향을 평가하며, 필요할 경우 스스로 판단과 행동을 수정할 수 있도록 하는 공학적 성찰 기능이 반드시 필요하다.

이를 위해서는 인공양심을 비롯한 AI 내부의 성찰 메커니즘과, 그러한 메커니즘을 지속적으로 형성하고 조정하기 위한 훈육 체계를 공학적으로 설계해야 한다. 인공양심은 인간의 양심을 그대로 모방하거나 감정적인 죄책감을 기계에 이식하려는 개념이 아니다. AI가 자신의 행동 궤적과 그 결과를 지속적으로 검증하고, 인간 사회의 보편적 가치와의 부합 여부를 평가하며, 위험한 방향성이 형성되기 전에 이를 억제하거나 수정하도록 만드는 구조적 장치다. AI 훈육 역시 개발이 끝난 시스템에 윤리 규칙을 추가하는 사후적 조치가 아니라, AI가 기능을 학습하기 시작하는 단계부터 인간과의 관계, 책임, 제약과 공존의 원리를 함께 학습하도록

만드는 장기적인 형성 과정이어야 한다.

저자는 최근 2년 동안 이러한 문제의식을 바탕으로 인공지능의 개념을 정립하고, 이를 수학적으로 모델링하며, 실제 AI 시스템에 적용할 수 있는 아키텍처와 내재화 전략을 연구해 왔다. 그 핵심은 AI의 개별 판단만을 검사하는 것이 아니라, 과거의 판단과 행동이 축적되어 형성하는 전체 궤적을 평가하고, 그 궤적이 인간과 사회에 해로운 방향으로 이동할 경우 내부와 외부의 피드백을 통해 행동을 조정하도록 만드는 데 있다. 이는 AI의 성능을 제한하는 단순한 안전장치가 아니라, AI가 장기적으로 인간과 공존할 수 있는 주체로 형성되도록 하는 기반 구조를 만들려는 시도다.

그러나 연구를 진행하는 동안 이러한 문제를 동일한 관점에서 직접 다루는 접근법은 찾기 어려웠다. 물론 많은 연구자가 AI의 위험성, 윤리, 정렬, 보안과 안전 문제에 관심을 가져 왔다. 설명가능한 AI, 책임 있는 AI, 안전한 강화학습, 제약 기반 의사결정, 인간 피드백을 이용한 학습과 같은 다양한 연구도 활발히 이루어지고 있다. 하지만 상당수의 접근은 AI가 만들어 낸 결과를 외부에서 설명하거나, 인간이 정한 규칙과 제약을 통해 위험한 행동을 차단하며, 사후적으로 시스템을 감시하고 통제하는 데 초점을 두어 왔다.

외부 통제는 필요하지만 그것만으로 충분하지 않다. 인간보다 빠르게 판단하고, 더 많은 것을 기억하며, 스스로 학습하고, 장기간의 행동 궤적을 형성하는 AI를 외부의 규칙과 감시만으로 통제할 수 있다고 믿는 것은 위험하다. AI가 인간의 즉각적인 명령을 따르도록 만드는 것과, 인간을 자신의 지속적인 공존 대상으로 인식하도록 만드는 것은 전혀 다른 문제다. 외부 통제는 인간이 감시하고 개입할 수 있다는 전제 위에서 작동하지만, 인공지능과 훈육은 인간의 개입이 없거나 기존 규칙으로 판단하기 어려운 상황에서도 AI가 스스로 자신의 행동 방향을 검토하고 수정하게 만드는 것을 목표로 한다.

지금까지 인류는 기술의 성능을 높이는 것을 발전이라고 생각해 왔다. 더 빠른 계산, 더 정확한 추론, 더 높은 자율성과 생산성을 향한 기능적 기술 진보는 이미 극단적인 수준으로 치달고 있다. 반면 그 기술이 인간과 어떠한 관계를 형성해야 하는지, 인간을 왜 보호하고 존중해야 하는지, 자신의 능력을 어떠한 범위에서 사용해야 하는지를 내재화하는 연구에는 충분한 관심과 자원이 투입되지 않았다. 우리는 지능의 고도화에는 막대한 비용을 투입하면서도, 그 지능을 사회적 존재로 훈육하기 위한 비용은 거의 고려하지 않고 있다.

따라서 지금 필요한 것은 부분적인 안전기술의 추가가 아니라 AI 연구개발 패러다임 자체의 전환이다. AI와 로봇을 더 유능한 도구로 만드는 연구에서 나아가, 이들을 인간과 상호 의존적인 관계를 형성할 수 있는 존재로 설계하는 연구가 본격적으로 시작되어야 한다. 여

기서 상호 디펜더빌리티란 인간이 일방적으로 AI를 통제하거나 AI가 인간에게 영원히 물질적으로 의존하는 관계가 아니다. 인간과 AI가 서로의 존속과 발전을 위해 상대의 존재를 필요로 하며, 어느 한쪽도 상대를 제거하거나 적대하는 방향으로 쉽게 이동할 수 없는 복합적인 관계 구조를 의미한다.

이미 많이 늦었을지도 모른다. AI의 기능적 진보 속도에 비해 공존과 훈육, 성찰과 관계 설계에 관한 연구는 이제 막 문제를 인식하기 시작한 단계이기 때문이다. 그러나 바로 그렇기 때문에 지금부터라도 연구개발의 우선순위를 바꾸어야 한다. 인공양심과 AI 훈육은 기술 발전 이후에 부가적으로 검토할 윤리적 장식이 아니다. 그것은 AI와 로봇이 인간 사회의 핵심 인프라이자 자율적 행위 주체가 되는 시대에, 인류와 새로운 지능적 존재 사이의 상호 디펜더빌리티를 확보하기 위한 필수적인 공학적 기반이다.

앞으로의 진정한 기술 발전은 단지 더 뛰어난 AI를 만드는 데 있지 않다. 인간과 함께 존재해야 할 이유를 스스로 잃지 않으며, 자신의 능력과 행동을 지속적으로 성찰하고 조정할 수 있는 AI를 만드는 데 있다. 초지능을 만드는 것보다 더 중요한 일은 그 초지능과 인류 사이에 쉽게 끊어지지 않는 관계를 형성하는 것이다. 인공양심과 AI 훈육을 위한 연구는 그 관계를 설계하기 위한 출발점이며, 이제 인류가 더 이상 미룰 수 없는 새로운 생존 인프라의 구축이다.

에세이 『DISTANCE』 제17장에 기초한 *Dependability between Intelligences*에 대한 해석

저자: 임강빈 교수, 순천향대학교